

# MODELO LINEAR CLÁSSICO

Frederico Machado Almeida  
`frederico.almeida@unb.br`

Departamento de Estatística  
Instituto de Exatas  
Universidade de Brasília

# Inverso Generalizado, $g$ -inverso

- O conceito clássico de inversa de uma matriz apresentada anteriormente (Slide 21, Aula 01), supõem que a matriz  $A$  seja quadrada e não singular, i.e.,  $|A| \neq 0$ .
- Acontece com alguma frequência em Estatística situações em que a matriz  $A$  não é quadrada, ou mesmo, caso seja, pode ocorrer de ser singular.
- Para contornar situações descritas no item anterior, uma teoria unificada é desejável. Tal teoria consiste em usar uma técnica que permite obter a inversa de uma matriz mesmo que ela seja singular ou não quadrada.

# Inverso Generalizado, $g$ -inverso

- Antes de apresentar a definição do  $g$ -inverso vamos considerar os seguintes resultados:
- Sejam  $A$  e  $B$  matrizes  $m \times n$ . Considere igualmente as seguintes matrizes  $C_{p \times m}$  e  $D_{n \times p}$ 
  - Se  $CA = CB$  então  $A = B$
  - Se  $AD = BD$  então  $A = B$
  - Se  $CAD = CBD$  então  $A = B$
  - $AB = AC$  se e somente se  $A^\top AB = A^\top AC$
  - $EA^\top = FA^\top$  se e somente se  $EA^\top A = FA^\top A$ .

# Inverso Generalizado, $g$ -inverso

Seja  $A$  uma matriz  $m \times n$ ;  $\mathbf{x}$  um vetor  $n$ -dimensional e  $\mathbf{y}$  um vetor  $m$ -dimensional. De tal forma que,  $\mathbf{y}$  pode ser escrito da seguinte forma,  $\mathbf{y} = A\mathbf{x}$ .

- **Definição 1:** Uma matriz  $G$  é dita ser inversa generalizada ( $g$ -inversa), se e somente se  $\mathbf{x} = G\mathbf{y}$  é solução de  $\mathbf{y} = A\mathbf{x}$ , então, segue que  $G \equiv A^{-1}$ .
- **Definição 2:** De acordo com a definição anterior, um inverso generalizado ( $g$ -inverso) de uma matriz  $m \times n$ ,  $A$  é uma matriz  $G_{n \times m}$  se ela satisfaz a seguinte relação:

$$AGA = A \tag{1}$$

- Denotamos o  $g$ -inverso por  $A^{-1}$ .

# Inverso Generalizado, $g$ -inverso

**Nota 2:** Para qualquer matriz  $A \in \mathcal{R}^{m \times n}$ , sua inversa generalizada sempre existirá, no entanto, ela não será única.

Para verificar tal afirmação, assumamos que  $A = [1, 2] \in \mathcal{R}^{1 \times 2}$ . A sua inversa generalizada será a matriz  $G = [x, y]^T \in \mathcal{R}^{2 \times 1}$  satisfazendo:

$$AGA = A \text{ então, } [1, 2] \begin{bmatrix} x \\ y \end{bmatrix} [1, 2] = (x + 2y)[1, 2] = [1, 2].$$

Este resultado mostra que, qualquer vetor  $G = \begin{bmatrix} x \\ y \end{bmatrix} \in \mathcal{R}^{2 \times 1}$  satisfazendo a equação  $x + 2y = 1$  será uma inversa generalizada de  $A$ . Por exemplo,

$$G = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \text{ ou } G = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

# Inverso Generalizado, $g$ -inverso

A matriz inversa generalizada é particularmente importante para resolver sistemas lineares no qual seus coeficientes estão em  $A$ .

## Teorema

A matriz  $G$ ,  $g$ -inverso de uma matriz real  $A$  sempre existe, e  $G = A^{-1}$  se  $A$  é não singular.

Exemplo 1: Prove que,

$$A_1^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \text{ e } A_2^{-1} = \begin{bmatrix} -42 & 18 \\ -2 & 2 \\ 1 & 0 \end{bmatrix}$$

são inversas generalizadas de

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \end{bmatrix}.$$

# Inverso Generalizado, $g$ -inverso

Seja  $A_{n \times n}$  uma matriz de posto  $r$ , se  $G$  denota a inversa generalizada de  $A$ , então,

- $A^{-1}G$  e  $GA^{-1}$  são idempotente
- $(I - A^{-1}G)$  e  $(I - GA^{-1})$  são idempotentes

Seja  $G$ ,  $g$ -inverso de  $A^\top A$ , então

- $G^\top$  é  $g$ -inverso de  $A^\top A$
- $GA^\top$  é  $g$ -inverso de  $A$ , tal que  $AGA^\top A = A$
- $AGA^\top$  é invariante a escolha de  $G$ , ou seja,

$$AG_1 A^\top = AG_2 A^\top$$

- $AGA^\top$  é simétrica.

# Inverso Generalizado, $g$ -inverso

A matriz  $\mathbf{X}^\top \mathbf{X}$  tem um papel importante na Estatística, com particular aplicação nas equações dos mínimos quadrados. Propriedades do  $g$ -inverso para  $\mathbf{X}^\top \mathbf{X}$ , são de extrema importância.

## Teorema

Seja  $(\mathbf{X}^\top \mathbf{X})^{-1}$  uma inversa generalizada de  $\mathbf{X}^\top \mathbf{X}$ . Então, as seguintes propriedades são válidas:

- 1  $\left[ (\mathbf{X}^\top \mathbf{X})^{-1} \right]^\top$  é também uma  $g$ -inversa de  $\mathbf{X}^\top \mathbf{X}$ .
- 2  $\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} = \mathbf{X}$ , isto é,  $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$  é uma  $g$ -inversa de  $\mathbf{X}$ .
- 3  $\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}$  é invariante para  $(\mathbf{X}^\top \mathbf{X})^{-1}$ .
- 4  $\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}$  é simétrica, mesmo que  $(\mathbf{X}^\top \mathbf{X})^{-1}$  seja simétrica ou não.



# Algumas Propriedades Matricial

Considere as seguintes notações:

- $A_{n \times n}$  é uma matriz de constantes
- $\mathbf{x}_{n \times 1}$  é um vetor de variáveis (ou parâmetros)
- $\mathbf{a}_{n \times 1}$  é um vetor de constantes.

Derivadas de Matrizes:

- $\frac{\partial \mathbf{a}^\top \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$
- $\frac{\partial \mathbf{x}^\top \mathbf{x}}{\partial \mathbf{x}} = 2\mathbf{x}$
- $\frac{\partial \mathbf{a}^\top A \mathbf{x}}{\partial \mathbf{x}} = A^\top \mathbf{a}$
- $\frac{\partial \mathbf{x}^\top A \mathbf{x}}{\partial \mathbf{x}} = A\mathbf{x} + A^\top \mathbf{x}.$

# Algumas Propriedades Matricial

Frequentemente estamos interessados em calcular a média e a variância de vetores. Por exemplo, assuma que o vetor  $\mathbf{W}$  é obtido como uma combinação linear do vetor  $\mathbf{y}$  e a matriz  $A_{m \times n} = (a_{ij})$ , com  $i \in \{1, \dots, m\}$  e  $j \in \{1, \dots, n\}$ . Ou seja,  $\mathbf{W} = A\mathbf{y}$ . Tal que,  $\mathbb{E}(\mathbf{Y}) = \boldsymbol{\mu}$  e  $\text{Var}(\mathbf{Y}) = \sigma^2 I_n$ .

Assim, segue que:

- ①  $\mathbb{E}(A) = A$
- ②  $\mathbb{E}(\mathbf{W}) = \mathbb{E}(A\mathbf{Y}) = A\mathbb{E}(\mathbf{Y}) = A\boldsymbol{\mu}$
- ③  $\text{Var}(\mathbf{W}) = \text{Var}(A\mathbf{Y}) = A\text{Var}(\mathbf{Y})A^\top (*)$
- ④  $\mathbb{E}(A\mathbf{W}B) = A\mathbb{E}(\mathbf{W})B$
- ⑤  $\mathbb{E}(\mathbf{Y}^\top A\mathbf{Y}) = \text{tr}(A\Sigma) + \boldsymbol{\mu}^\top A\boldsymbol{\mu} \text{ (verifique!)},$

onde  $\Sigma = \sigma^2 I_n$ .  $(*) \text{Var}(\mathbf{Y}) = \mathbb{E}[(\mathbf{Y} - \mathbb{E}(\mathbf{Y}))(\mathbf{Y} - \mathbb{E}(\mathbf{Y}))^\top] = \mathbb{E}(\mathbf{Y}\mathbf{Y}^\top) - \boldsymbol{\mu}^\top \boldsymbol{\mu}$ .

# Regressão Linear Múltipla

- Podemos afirmar que estamos perante uma situação envolvendo o modelo de regressão múltipla quando se admite que a resposta  $Y$  pode ser modelada por meio de duas ou mais variáveis independentes.
- Assim, como na regressão linear simples, uma regressão linear múltipla supõem que função de regressão  $E(Y|X = x)$  é linearmente dependente dos preditores  $x_1, \dots, x_p$ .
- Regressões lineares são simples e comumente fornecem um descrição adequada e interpretável de como as variáveis exploratórias afetam as resposta.

# Regressão Linear Múltipla

- O modelo estatístico de uma regressão linear múltipla com  $p$ -variáveis explicativas  $(x_1, \dots, x_p)^\top$  é dado por:

$$Y = \beta_0 + \sum_{j=1}^p \beta_j x_j + \epsilon, \quad (2)$$

onde  $\beta_j$ 's são os coeficientes de regressão, e  $\epsilon$  o termo de erro.

- As variáveis  $x_j$ 's podem vir de diferentes fontes; a saber:
  - Inputs quantitativos (valores reais, medidas)
  - Transformação de inputs quantitativos (ex.: log,  $\sqrt{\cdot}$ , etc)
  - Expansão de base (ex.:  $x_2 = x_1^2$ ,  $x_3 = x_1^3$ , etc)
  - inputs qualitativos ("dummy" ex.: gênero, classes sociais, escolaridade)
  - Interação (ex.:  $x_3 = x_1 \cdot x_2$ )


# Regressão Linear Múltipla

- Como no caso da regressão linear simples, normalmente tem-se um banco de observações do tipo  $(x_1, y_1), \dots, (x_n, y_n)$ , cujo objetivo é estimar o vetor de parâmetros  $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$ .
- Ao estender a noção de regressão simples para regressão múltipla o método de mínimos quadrados continua sendo utilizado, no qual as estimativas dos  $\beta_i$ 's são escolhidas derivando a *SQE* em relação a  $(\beta_0, \beta_1, \dots, \beta_p)^\top$ . Ou seja,

$$\begin{aligned} SQE(\beta) &= \sum_{i=1}^n (Y_i - f(x_i, \beta))^2 \\ &= \sum_{i=1}^n \left( Y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \end{aligned}$$

# Regressão Linear Múltipla

Source: Elements of Statistical Learning (2nd Ed.) Hastie, Tibshirani & Friedman 2009 Chap 3



**FIGURE 3.1.** Linear least squares fitting with  $X \in \mathbb{R}^2$ . We seek the linear function of  $X$  that minimizes the sum of squared residuals from  $Y$ .

# Regressão Linear Múltipla

- Podemos representar tanto a regressão linear simples, assim como a regressão linear múltipla na forma matricial. Para tal, defina  $p = k + 1$  e

$$\mathbf{y}_{n \times 1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{X}_{n \times p} = \begin{pmatrix} 1 & X_{11} & \cdots & x_{1k} \\ 1 & X_{21} & \cdots & X_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & \cdots & X_{nk} \end{pmatrix}, \quad \boldsymbol{\beta}_{p \times 1} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}, \quad \boldsymbol{\epsilon}_{n \times 1} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}.$$

- Aqui,  $\mathbf{X}$  é chamada de matriz desenho (experimental ou de covariáveis). Assim, o modelo de regressão linear múltipla, pode ser escrito como:

$$\mathbf{y}_{n \times 1} = \mathbf{X}_{n \times p} \boldsymbol{\beta}_{p \times 1} + \boldsymbol{\epsilon}_{n \times 1}, \quad (3)$$

- Portanto,  $\mathbb{E}(\mathbf{Y}|\mathbf{X} = \mathbf{x}_i) = \mathbf{x}_i \boldsymbol{\beta}$ . Sendo  $\mathbf{x}_i$  um vetor  $1 \times p$ .

# Regressão Linear Múltipla

- Nesse caso, a primeira coluna da matriz  $\mathbf{X}_{n \times p}$  foi incluída para acomodar o intercepto.
- É importante salientar que, a menos que haja o problema de multicolinearidade, a matriz  $\mathbf{X}$  será de posto completo, i.e.,  $r(\mathbf{X}) = p$ .
- Tal como no modelo de regressão linear simples, temos que:
  - 1 Para  $\forall_i$ ,  $y_i$  é uma função linear de  $\mathbf{x}_i$
  - 2 Os  $\mathbf{x}_i$ 's são fixos (controlados) e medidos sem erros
  - 3 Os erros tem média 0, i.e.,  $\mathbb{E}(\epsilon) = \mathbf{0}$
  - 4 Os erros são homocedásticos
  - 5 Os erros são independentes
  - 6 De (3)-(5) segue que,  $\epsilon \sim \mathcal{NM}_n(\mathbf{0}_{n \times 1}, \sigma^2 \mathbf{I}_n)$ .



# Regressão Linear Múltipla

- Tal como no caso da regressão linear simples, da equação (3) segue que,  $\epsilon = \mathbf{y} - \mathbf{X}\beta$ .
- Sendo um vetor observado  $n \times 1$  de respostas, segue que, a  $SQE(\beta)$  será:

$$\begin{aligned} SQE(\beta) &= \epsilon^\top \epsilon = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{1i} \cdots - \beta_p x_{pi})^2 \\ &= (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta) \\ &= \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbf{X}^\top \mathbf{y} + \beta^\top \mathbf{X}^\top \mathbf{X} \beta. \end{aligned}$$

- Para minimizar a  $SQE(\beta)$  devemos derivar em relação ao vetor  $\beta$ , e igualar a 0. Isto é,

$$\frac{\partial}{\partial \beta} SQE(\beta) = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta) \text{ (verifique!)} \quad (4)$$

# Regressão Linear Múltipla

- Igualando (4) ao vetor nulo  $\mathbf{0}$ , e resolvendo o sistema resultante, obtemos:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

sendo  $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p)^\top$  os estimadores dos mínimos quadrados.

- Um caso particular, seria obter os estimadores dos mínimos quadrados no caso que  $\mathbf{X}$  é uma matriz  $n \times 2$  (**regressão linear simples**). Assim,

$$\mathbf{y}_{n \times 1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{X}_{n \times 2} = \begin{pmatrix} 1 & X_1 \\ 1 & X_2 \\ \vdots & \vdots \\ 1 & X_n \end{pmatrix}, \quad \boldsymbol{\epsilon}_{n \times 1} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}.$$

# Regressão Linear Múltipla

- Passo 1:

$$\mathbf{X}^T \mathbf{X} = \begin{pmatrix} 1 & 1 & \dots & 1 \\ X_1 & X_2 & \dots & X_n \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \\ X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} = \begin{pmatrix} n & \sum_{i=1}^n X_i \\ \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 \end{pmatrix}$$

- Passo 2: Observe que,

$$|\mathbf{X}^T \mathbf{X}| = n \sum_{i=1}^n X_i^2 - \left( \sum_{i=1}^n X_i \right)^2 = n \left[ \sum_{i=1}^n X_i^2 - n \bar{X}^2 \right] = n S_{XX}.$$

# Regressão Linear Múltipla

- **Passo 3:** Com base no resultado dos passos 1 e 2, segue que:

$$(\mathbf{X}^\top \mathbf{X})^{-1} = \frac{1}{nS_{xx}} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix} = \begin{pmatrix} \frac{\sum_{i=1}^n x_i^2}{nS_{xx}} & -\frac{\bar{x}}{S_{xx}} \\ -\frac{\bar{x}}{S_{xx}} & \frac{1}{S_{xx}} \end{pmatrix},$$

- **Passo 4:** Obter a quantidade,

$$\mathbf{X}^\top \mathbf{y}_{2 \times n, n \times 1} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{pmatrix}$$

- **Passo 5:** Por fim, obtemos (**Verifique!**)

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \begin{pmatrix} \bar{y} - \bar{x} \frac{S_{xy}}{S_{xx}} \\ \frac{S_{xy}}{S_{xx}} \end{pmatrix} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix}.$$

# Regressão Linear Múltipla

- Voltando para a situação envolvendo o modelo de regressão linear múltipla, a reta de regressão estimada no caso da regressão múltipla será:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X} \left( \mathbf{X}^{\top} \mathbf{X} \right)^{-1} \mathbf{X}^{\top} \mathbf{y} = \underset{n \times n}{\mathbf{H}} \underset{n \times 1}{\mathbf{y}},$$

sendo  $\mathbf{H} = \mathbf{X} \left( \mathbf{X}^{\top} \mathbf{X} \right)^{-1} \mathbf{X}^{\top}$  a **matriz de projeção** (ou **hat matrix**).

- A **matriz de projeção** apresenta propriedades de extrema importância na estatística.


# Regressão Linear Múltipla

## Propriedades da matriz de projeção:

- ①  $\mathbf{H}$  é simétrica, ou seja,  $\mathbf{H}^\top = \mathbf{H}$
- ②  $\mathbf{H}$  é idempotente, ou sejam  $\mathbf{H}^2 = \mathbf{H}$
- ③  $tr(\mathbf{H}) = \sum_{i=1}^n h_{ii} = p$ , sendo  $p$  o posto de  $\mathbf{X}$ , caso seja de posto completo
- ④  $\mathbf{H}$  é a matriz de projeção no plano gerado pelas colunas de  $\mathbf{X}$ , ou seja,  $\mathbf{H}\mathbf{X} = \mathbf{X}$ , veja a Figura a seguir.

# Regressão Linear Múltipla

Source: Elements of Statistical Learning (2nd Ed.) Hastie, Tibshirani & Friedman 2009 Chap 3



**FIGURE 3.4.** *Least squares regression by orthogonalization of the inputs. The vector  $x_2$  is regressed on the vector  $x_1$ , leaving the residual vector  $z$ . The regression of  $y$  on  $z$  gives the multiple regression coefficient of  $x_2$ . Adding together the projections of  $y$  on each of  $x_1$  and  $z$  gives the least squares fit  $\hat{y}$ .*

# Regressão Linear Múltipla

- Quando a matriz desenho  $\mathbf{X}$  não é de posto completo, isto é, quando  $r(\mathbf{X}) < p$ , então  $\hat{\beta}$  não pode ser estimado de forma única.
- Porém,  $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$  é único, pois,  $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$  unicamente define a projeção de  $\hat{\mathbf{y}}$  no espaço gerado por  $\mathbf{X}$ .
- Portanto apesar das infinitas soluções para  $\hat{\beta}$  temos que,  $\hat{\mathbf{y}}$  continua sendo estimado de forma única.



# Regressão Linear Múltipla

## Algumas propriedades importantes:

- 1 Conforme apresentado no caso da regressão linear simples, é possível mostrar que  $\hat{\beta}$  é um estimador não viesado, i.e.,  $\mathbb{E}(\hat{\beta}) = \beta$  com variância  $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$  (Verifique!).
- 2 Os elementos de  $\hat{\beta}$  são combinações lineares dos  $y_i$ 's, isto é,  $\hat{\beta} = \sum_{i=1}^n d_{ij} y_i$ . Sendo  $d_{ij}$  elementos da matriz  $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$ .
- 3 Com base nos resultados anteriores, segue que,  $\hat{\beta} \sim \mathcal{NM}_P(\beta, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$ , e  $\mathbf{y} \sim \mathcal{NM}_n(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$ .

# Regressão Linear Múltipla

- 4 Dada uma combinação linear dos parâmetros  $\mathbf{c}^\top \boldsymbol{\beta} = \sum_{j=1}^p c_j \beta_j$ , com  $\mathbf{c}^\top = (c_1, \dots, c_p)^\top$ , o estimador dos MQ's não viesado e de variância mínima é dado por  $\mathbf{c}^\top \hat{\boldsymbol{\beta}}$ . Tal que,

$$\mathbb{E}(\mathbf{c}^\top \hat{\boldsymbol{\beta}}) = \mathbf{c}^\top \boldsymbol{\beta} \text{ e } \text{Var}(\mathbf{c}^\top \hat{\boldsymbol{\beta}}) = \mathbf{c}^\top \text{Var}(\hat{\boldsymbol{\beta}}) \mathbf{c} = \sigma^2 \mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}.$$

Assim, seque imediatamente que,  
 $\mathbf{c}^\top \hat{\boldsymbol{\beta}} \sim \mathcal{N}(\mathbf{c}^\top \boldsymbol{\beta}, \sigma^2 \mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}).$

# Regressão Linear Múltipla

## Inferência sobre os $\hat{\beta}$ 's

- Seguindo a mesma ideia apresentada no MRL simples, a questão lógica que pode ser feita agora é: entre os coeficientes de regressão, quais deles são significativos para descrever as variações de  $\mathbf{y}$ ?
- As hipóteses para testar individualmente a significância de qualquer coeficiente de regressão, digamos  $\beta_j$  são:

$$H_0 : \beta_j = 0 \text{ vs } H_0 : \beta_j \neq 0,$$

caso a  $H_0$  não seja rejeitada, isso significa que o fator  $x_j$  não é significativo, e portanto, pode ser retirado das análises.

# Regressão Linear Múltipla

## Inferência sobre os $\hat{\beta}$ 's

- A estatística de teste é:

$$t_{obs} = \frac{\hat{\beta}_j}{\sqrt{\text{Var}(\hat{\beta}_j)}} = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{c_{jj}}} \sim t_{n-p}.$$

onde  $c_{jj}$  é o  $j$ -ésimo elemento da diagonal da matriz  $(\mathbf{X}^\top \mathbf{X})^{-1}$ .

- É importante lembrar que,  $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$  e, portanto, a variância de  $\hat{\beta}_j$  é dada por:

$$\text{Var}(\hat{\beta}_j) = \sigma^2 c_{jj}.$$

- A  $H_0$  será rejeitada sempre que  $|t_{obs}| > t_{(\alpha/2, n-p)}$ .

# Regressão Linear Múltipla

## Inferência sobre os $\hat{\beta}$ 's

- Assumindo um nível de confiança  $100(1 - \alpha)\%$ , o intervalo de confiança para o  $j$ -ésimo coeficiente de regressão ( $j = 0, \dots, p$ ) é dado por:

$$\hat{\beta}_j - t_{(\frac{\alpha}{2}, n-p)} \sqrt{\hat{\sigma}^2 c_{jj}} \leq \beta_j \leq \hat{\beta}_j + t_{(\frac{\alpha}{2}, n-p)} \sqrt{\hat{\sigma}^2 c_{jj}},$$

sendo  $\hat{\beta}_j$  a estimativa pontual de  $\beta_j$ , e  $t_{(\frac{\alpha}{2}, n-p)}$  quantis da distribuição  $t$ -Student com  $n - p$  graus de liberdade.

**Obs.:** podemos igualmente construir o intervalo de confiança para o parâmetro  $\mu_{y|x_0} = \mathbb{E}(Y|X = x_0)$ .

# Regressão Linear Múltipla

## Análise de Variância (ANOVA)

- Note que até o momento não foi necessária nenhuma hipótese quanto ao ajuste do modelo.
- Para questões de inferência, vamos supor que  $\epsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ . Sendo  $\sigma^2 \mathbf{I}_n$  matriz de variância e covariância.
- Conforme apresentado no caso da regressão linear simples, os resíduos serão obtidos fazendo a seguinte diferença:

$$\mathbf{e}_{n \times 1} = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{H}\mathbf{y} = (\mathbf{I} - \mathbf{H})\mathbf{y}.$$

# Regressão Linear Múltipla: ANOVA

- Pode-se mostrar facilmente que  $\mathbf{I}_n - \mathbf{H}$  é uma matriz simétrica e idempotente.
- Usando a mesma ideia do modelo de regressão linear simples, pode-se mostrar facilmente que:

$$\begin{aligned}\text{Var}(\mathbf{e}) &= \text{Cov}[(\mathbf{I}_n - \mathbf{H})\mathbf{Y}, (\mathbf{I}_n - \mathbf{H})\mathbf{Y}] \\ &= (\mathbf{I}_n - \mathbf{H}) \text{Var}(\mathbf{Y}) (\mathbf{I}_n - \mathbf{H})^\top \\ &= \sigma^2 (\mathbf{I}_n - \mathbf{H}).\end{aligned}$$

- Como  $\sigma^2$  é desconhecido, segue que,  $\text{Var}(\mathbf{e}) = QME (\mathbf{I}_n - \mathbf{H})$ . Onde,

$$QME = \frac{SQE(\beta)}{n - p} = \frac{\mathbf{y}^\top (\mathbf{I}_n - \mathbf{H}) \mathbf{y}}{n - p},$$

onde  $n - p = \text{tr}(\mathbf{I}_n - \mathbf{H}) = \text{tr}(\mathbf{I}_n) - \text{tr}(\mathbf{H})$ .

# Regressão Linear Múltipla: ANOVA

## ANÁLISE DE VARIÂNCIA

- Para construir uma tabela de ANOVA, a soma dos quadrados dos totais é dada por:

$$SQT = \sum_{i=1}^n (y_i - \bar{y})^2, \text{ em termo matricial fica}$$

$$= \left( \mathbf{y} - \frac{1}{n} \mathbf{1} \mathbf{1}^T \mathbf{y} \right)^T \left( \mathbf{y} - \frac{1}{n} \mathbf{1} \mathbf{1}^T \mathbf{y} \right)$$

$$= \mathbf{y}^T \left( \mathbf{I}_n - \frac{1}{n} \mathbf{J} \right) \mathbf{y}$$

$$SQReg = SQT - SQE = \mathbf{y}^T \left( \mathbf{H} - \frac{1}{n} \mathbf{J} \right) \mathbf{y}.$$



# Regressão Linear Múltipla: ANOVA

- Cada soma dos quadrados apresentada pode ser vista da forma  $\mathbf{y}^\top \mathbf{A} \mathbf{y}$ , onde  $\mathbf{A}$  tem a seguinte formulação: (i)  $\mathbf{I} - \frac{1}{n} \mathbf{J}$ ; (ii)  $\mathbf{I} - \mathbf{H}$ ; (iii)  $\mathbf{H} - \frac{1}{n} \mathbf{J}$ .
- As matrizes dos casos (i)-(iii) são simétricas e idempotentes. A prova é trivial, e segue o fato de que  $\mathbf{I}$ ,  $\frac{1}{n} \mathbf{J}$  e  $\mathbf{H}$  serem simétricas e idempotentes.
- De igual forma, a matriz  $\mathbf{H} - \frac{1}{n} \mathbf{J}$  é simétrica e idempotente. A prova deste fato resume-se em mostrar que  $\mathbf{HJ} = \mathbf{J}$  que é simétrica, mas não é idempotente.

# Regressão Linear Múltipla: ANOVA

- Usando o fato de que  $\mathbb{E}(\mathbf{Y}^\top \mathbf{A} \mathbf{Y}) = \sigma^2 \text{tr}(\mathbf{A}) + \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}$ , podemos mostrar que (**verifique!**):
  - 1  $\mathbb{E}(SQT) = (n - 1)\sigma^2 + (\mathbf{X}\boldsymbol{\beta})^\top (\mathbf{I} - \frac{1}{n}\mathbf{J})(\mathbf{X}\boldsymbol{\beta}),$
  - 2  $\mathbb{E}(SQE) = (n - p)\sigma^2 + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} - (\mathbf{X}\boldsymbol{\beta})^\top \mathbf{H} \mathbf{X} \boldsymbol{\beta} = (n - p)\sigma^2,$
  - 3  $\mathbb{E}(SReg) = (p - 1)\sigma^2 + \boldsymbol{\beta}^\top \mathbf{X}_1^\top \mathbf{X}_1 \boldsymbol{\beta},$  sendo  $\mathbf{X}_1$  a matriz experimental excluindo a coluna de 1's.
- Assim, o estimador não tendencioso para a variância dos erros é,

$$QME = \frac{\mathbb{E}(SQE)}{n - p} = \sigma^2.$$

# Regressão Linear Múltipla: ANOVA

- O teste da análise de variância para a regressão linear múltipla tem por objetivo, testar as seguintes hipóteses:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$$

$$H_1 : \exists \beta_j \neq 0 \text{ para } j = 1, \cdots, p$$

**Tabela:** Análise de variância para a regressão linear múltipla.

F.V	SQ	G.L	QM	F
Regressão	$SQReg$	$p - 1$	$\frac{SQReg}{p-1}$	$F_{cal} = \frac{QMReg}{QME} \overset{\text{sob } H_0}{\sim} F_{(\alpha, p-1, n-p)}$
Erro	$SQE$	$n - p$	$\frac{SQE}{n-p}$	
Total	$SQT$	$n - 1$		

- Assim, a  $H_0$  será rejeitada à favor da  $H_1$  se  $F_{cal} > F_{(\alpha, p-1, n-p)}$ .

# Regressão Linear Múltipla

Exemplo: Aplicação do MRLM no R

## Seleção de Modelos

- Existem duas razões do porquê as vezes não nos satisfazemos com o estimador de mínimos quadrados.
  - 1 Precisão da Predição: Os estimadores de mínimos quadrados normalmente são não viciados mas possuem grande variabilidade.
  - 2 Interpretação: Com um grande número de preditores, gostaríamos de escolher um subconjunto que exiba os fatores principais. Para entender o problema de forma geral estamos dispostos a sacrificar pequenos detalhes.

# Seleção de Modelos

- Iremos discutir 3 métodos de seleção de modelos:
  - Forward Selection
  - Backward Selection
  - Stepwise Selection

# Akaike Information Criterion

- 1 A “Akaike information criterion” (AIC) é uma medida de qualidade ajuste para modelos estatísticos.
- 2 O AIC é baseado no conceito de entropia, que tenta medir a perda de informação dado um modelo para descrever a realidade.
- 3 Pode se dizer que o AIC é uma troca entre o viés e a variabilidade do modelo construído, ou de forma mais geral, uma troca entre a complexidade e a precisão do modelo.

$$AIC = 2p - 2 \log L(\beta),$$

onde  $L(\beta)$  é a função de verossimilhança e  $p$  é o número de parâmetros no modelo.

- 4 Portanto, o AIC penaliza pela complexidade do modelo ( $p$ ) e mede a precisão através da função de verossimilhança  $L(\beta)$ .

# Forward Selection

- 1 Determine todos os fatores que serão usados, o modelo completo.
- 2 A primeira variável que entra no modelo é aquela no qual o AIC foi minimizado. Adiciona a variável caso o AIC seja inferior ao AIC do modelo com somente o intercepto.
- 3 Encontre os AIC referentes a adição de uma variável no presente modelo.
- 4 Se tiver algum fator que diminua o AIC, o inclua e retorne para 3. Caso contrário pare.



# Backward Selection

- 1 Determine o modelo completo.
- 2 Encontre o AIC referentes a remoção de uma variável por vez no presente modelo.
- 3 Retire do modelo o fator no qual a remoção diminua mais o AIC e retorne para 2. Caso contrário pare.

# Stepwise Selection

- O método stepwise é uma mistura entre os métodos forward e o backward. Basicamente o método permite que se adicione e/ou retire fatores passo a passo.
- ① Defina o modelo completo
- ② Determine se a remoção de algum fator reduz o AIC
- ③ Encontre o AIC para a remoção das variáveis presentes e o AIC para a adição das variáveis que já foram removidos.
- ④ Inclua ou retire o fator que reduz o AIC e volte para 3. Caso contrário pare.

- Esses modelos são gulosos e podem parecer sub-ótimos se comparado ao melhor subconjunto.
- Porém existem razões para escolher esses métodos
  - 1 Não é preciso determinar  $p$ .
  - 2 É computacionalmente eficiente se comparado ao método do subconjunto.
  - 3 Estatisticamente os métodos gulosos fazem uma busca mais restrita nos modelos; incluindo um viés maior mas reduzindo a variabilidade.

O critério BIC-Bayesian Information Criterion, é dado pela seguinte expressão:

$$BIC = p \log n - 2 \log L(\beta).$$

**Obs.:** O critério  $BIC$  penaliza mais fortemente modelos com um maior número de parâmetros do que o  $AIC$  tendendo, dessa forma, a selecionar modelos com um menor número de parâmetros.

# Regressão Linear Múltipla

## Multicolinearidade

### O que é colinearidade?

- Suponha que temos que a matriz experimental  $\mathbf{X}$ . A colinearidade é um fenômeno que ocorre quando alguns preditores de  $\mathbf{X}$  são combinações lineares dos demais, i.e., quando a matriz  $\mathbf{X}^T \mathbf{X}$  é singular.
- Quando  $\mathbf{X}^T \mathbf{X}$  é singular, ou próxima de ser, o estimador dos mínimos quadrados para  $\hat{\beta}$  não será único ( $r(\mathbf{X}) < p$ ). Neste caso, podemos dizer que há colinearidade (ou multicolinearidade).
- A presença da colinearidade causa sérios problemas com a estimação de  $\hat{\beta}$  e outras quantidades associadas, como a interpretação.

# Regressão Linear Múltipla

- Suponha que temos dois preditores,  $x_1$  e  $x_2$ . Então,  $x_1$  e  $x_2$  são ditos serem colineares se existe constantes  $c_0, c_1$  e  $c_2$  tal que:

$$c_1 x_1 + c_2 x_2 = c_0,$$

e aproximadamente colineares se

$$c_1 x_1 + c_2 x_2 \approx c_0.$$

- Essa ideia pode ser estendida para o caso em que temos  $x_1, \dots, x_k$  preditores. Logo,  $x_1, \dots, x_k$  são ditos serem colineares se temos,

$$c_1 x_1 + \dots + c_k x_k = c_0,$$

e aproximadamente colineares se

$$c_1 x_1 + \dots + c_k x_k \approx c_0.$$

# Regressão Linear Múltipla

- No contexto do modelo de regressão linear  $\mathbf{y} = \mathbf{X}\beta + \epsilon$ . Então, o modelo é dito ser afetado pelo problema da colinearidade ou multicolinearidade, se pelo menos uma coluna de  $\mathbf{X}$  é combinação linear de outras.
- Matematicamente temos que, a colinearidade ocorre se

$$|\mathbf{X}^T \mathbf{X}| = 0.$$

- Porém, na prática tratamos o problema de multicolinearidade quando

$$|\mathbf{X}^T \mathbf{X}| \approx 0.$$

# Regressão Linear Múltipla

## Qual o problema de multicolinearidade?

- Vamos pensar no modelo simples com 2 covariáveis,  
 $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon$ , com  $\mathbb{E}(\epsilon) = 0$  e  $\text{Var}(\epsilon) = \sigma^2$ .
- Seja  $r_{12}$  a correlação amostral de Pearson  $x_1$  e  $x_2$ , e seja  $S_{x_j}^2$  a variância amostral de  $x_j$ . Portanto, se  $\hat{\beta}_j$  é o estimador de mínimos quadrados de  $\beta_j$ . Pode se mostrar que:

$$\text{Var}(\hat{\beta}_j) = \sigma^2 \left( \frac{1}{1 - r_{12}^2} \right) \left( \frac{1}{(n-1)S_{x_j}^2} \right), \text{ para } j = 1, 2$$

- Assim,  $\text{Var}(\hat{\beta}_j) \rightarrow \infty$  se  $r_{12}^2 \rightarrow 1$ , e  $\text{Var}(\hat{\beta}_j)$  é minimizada quando  $r_{12}^2 = 0$ .

# Regressão Linear Múltipla

- Lembre-se que o estimador de mínimos quadrados é da forma

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

com variância  $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$ .

- A multicolinearidade gera uma matriz  $\mathbf{X}^\top \mathbf{X}$  aproximadamente singular, o que pode causar estimativas pouco precisas de  $\hat{\beta}$  com uma variância alta.
- Por conta disso, o teste  $t$ -Student para testar a significância de  $\beta_j$ , digamos  $H_0 : \beta_j = 0$  pode ser enganoso.



# Regressão Linear Múltipla

## Sinais da presença de multicolinearidade:

- A correlação entre pares de preditores é surpreendentemente grande (use a matriz de correlações)
- Se alguns dos coeficientes forem estimados com o sinal trocado, baseando em algum conhecimento prévio
- Preditores conhecidos de serem importantes (através de conhecimento a priori) possuem uma estatística  $t$  pequena
- Remoção de uma linha ou coluna da matriz  $\mathbf{X}$  produz uma mudança surpreendente no modelo ajustado.
- Examine os autovalores da matriz  $\mathbf{X}^T \mathbf{X}$ , e denote por  $\lambda_1$  o maior autovalor entre os demais, em ordem crescente. Em geral, autovalores menores indicam a presença de multicolinearidade (facilmente obtido no R).

# Regressão Linear Múltipla

- O fator de inflação da variância (VIF) para o  $j$ -ésimo preditor  $x_j$  é definido como

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

onde  $R_j^2$  é o coeficiente de determinação múltiplo,  $R^2$  quando  $x_j$  é regressado nos outros  $k - 1$  regressores, para  $j = 1, 2, \dots, k$ .

- Regra básica:

$\text{VIF} \geq 10$  é uma indicação de multicolinearidade severa

$\text{VIF} > 5$  é uma indicação de multicolinearidade moderada, e deve ser investigada.

# Regressão Linear Múltipla

## Remédios para multicolinearidade:

Essa técnica é particularmente útil para tirar a correlação entre os preditores e o intercepto, e também é muito útil em modelos que contêm interação de alta ordem (interações maiores do que quadrática).

- Centrar e/ou escalonar e/ou padronizar empiricamente as variáveis preditoras. Ou seja, se  $x_{1j}, x_{2j}, \dots, x_{nj}$  são valores observados de  $x_j$  para cada indivíduo, defina  $\bar{x}_j$  e  $S_{x_j}$  como sendo a média e desvio-padrão amostral dos  $x_{ij}$ 's.
  - Centrar:  $x_{ij} - \bar{x}_j$
  - Escalonar:  $x_{ij} / S_{x_j}$
  - Padronizar:  $(x_{ij} - \bar{x}_j) / S_{x_j}$ .

# Regressão Linear Múltipla

- Remover um ou vários preditores (normalmente aquelas que possuem alto valores de VIF) do modelo
- Combinar alguns preditores lineares
- Quebrar o padrão de multicolinearidade adicionando novas observações, i.e., adicionando mais dados
- Usando algum tipo de regressão penalizada:
  - ridge regression
  - lasso regression

# Regressão Linear Múltipla

## Aplicação do MRLM no R

# Regressão Linear Múltipla

## Análise de Resíduos e Medidas Corretivas

Seguindo a mesma ideia apresentada no modelo de regressão linear simples (MRLS), a análise de resíduos objetiva:

- Avaliar o quão o modelo proposto se ajusta aos dados
- Verificar se existe(m) ou não valor(es) estimado(s) fora do padrão esperado (valores de alavancagem ou outliers)
- Verificar a presença ou não de multi(colinearidade) entre as variáveis explicativas
- Verificar a validade da suposição de homoscedasticidade, entre outros aspectos.

# Regressão Linear Múltipla

- No que diz respeito a análise dos resíduos, mas concretamente aos pontos influentes (pontos de alavancagem), considere a seguinte matriz experimental  $\mathbf{X}_{n \times p}$ . Assim, é possível mostrar que, os elementos da matriz projeção

$$\mathbf{H} = \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top,$$

são tais que,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}, \quad \forall i = j$$

$$h_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}, \quad \forall i \neq j$$

Nota: Verifique assumindo que  $\mathbf{X}$  é uma matriz  $n \times 2$  quaisquer.

# Regressão Linear Múltipla

- Lembrando, temos que  $e_i \sim \mathcal{N}(0, \sigma^2(1 - h_{ii}))$ . Assim,

$$\frac{e_i}{ep(e_i)} = \frac{e_i}{\sigma\sqrt{1 - h_{ii}}} \sim \mathcal{N}(0, 1).$$

**Resíduo Interno Studentizado:** O resíduo interno studentizado, é definido como:

$$r_i = \frac{e_i}{ep(e_i)} = \frac{e_i}{\hat{\sigma}\sqrt{1 - h_{ii}}} = \frac{e_i}{\sqrt{QME(1 - h_{ii})}}.$$

- Apesar de assumirmos que  $\epsilon_i$  devem ser independentes, eles apresentam uma pequena correlação, tal que,  $\text{Cov}(r_i, r_j) = -h_{ij}\sigma^2$  ( $i \neq j$ ) e portanto,

$$\text{Corr}(r_i, r_j) = \frac{-h_{ij}}{\sqrt{(1 - h_{ii})(1 - h_{jj})}} \approx 0 \quad (i \neq j).$$



# Regressão Linear Múltipla

- Sob a suposição de linearidade e normalidade, (Cook and Weisberg, 1982) mostraram que,

$$\frac{r_i^2}{n-p} \sim \text{Beta} \left( \frac{1}{2}, \frac{n-p}{2} \right),$$

Assim,  $|r_i| \leq t_{(\alpha/2, n-p)}$

- Um gráfico de  $r_i$  versus  $\hat{Y}_i$  ainda é útil para detectar discrepâncias das hipóteses do modelo. Espera-se ver um padrão aleatório e  $|r_i| \leq 2$ .

# Regressão Linear Múltipla

- **DFFITS**: É uma medida que avalia a alteração provocada no valor ajustado  $\hat{y}$ , pela retirada da  $s$ -ésima observação no banco de dados. Por definição, temos que,

$$DFFITS_i = \frac{\hat{y}_i - \hat{y}_{i(s)}}{\sqrt{QME_{(s)} h_{ii}}},$$

onde  $\hat{y}_{i(s)}$  denota o valor predito para  $s$ -ésima observação obtida ao deletar a  $s$ -ésima observação para ajustar o modelo de regressão e  $QME_{(s)}$  é o  $QME$  obtido ao deletar a  $s$ -ésima observação do modelo de regressão.

- Regra básica:  
Se  $|DFFITS_i| \geq 1$  (para bancos de dados pequenos ou médios)  
Se  $|DFFITS_i| \geq 2\sqrt{\frac{p}{n}}$ , com  $p = k + 1$  (para bancos de dados grandes), a  $i$ -ésima observação é considerada influente.

# Regressão Linear Múltipla

## Influência sobre todos os valores ajustados - Distância de Cook:

- É uma medida de afastamento do vetor de estimativas provocada pela retirada da  $i$ -ésima observação.
- Sua expressão é muito semelhante com aquela usada no caso da influência nos valores ajustados (DFFITS) mas, que usa como estimativa de variância residual, aquela obtida com todas as  $n$  observações.
- Para começar, considere a seguinte formulação matemática. Seja  $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ . Considere também,  $\hat{\boldsymbol{\beta}}_{(i)} = (\mathbf{X}_{(i)}^\top \mathbf{X}_{(i)})^{-1} \mathbf{X}_{(i)}^\top \mathbf{y}_{(i)}$ , onde  $\mathbf{X}_{(i)}$  é a matriz  $\mathbf{X}$  com a  $i$ -ésima linha deletada, e  $\mathbf{y}_{(i)}$  é o vetor  $\mathbf{y}$  com a  $i$ -ésima observação deletada.

# Regressão Linear Múltipla

- O objetivo é comparar  $\hat{\beta}$  com  $\hat{\beta}_{(i)}$  para determinar se a  $i$ -ésima observação é influente, e determinar sua magnitude.
- Para tal, Cook (1972) propôs que a influência da  $i$ -ésima observação deve ser medida em função da distância quadrática,

$$D_i = \frac{(\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(i)})^\top (\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(i)})}{p \times QME},$$

onde  $\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$ ,  $\hat{\mathbf{y}}_{(i)} = \mathbf{X}\hat{\beta}_{(i)}$ ,  $p$  é o número de coeficientes de regressão, e  $QME$  é a estimativa da variância residual para todas as observações.

- Como  $\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(i)} = \mathbf{X}(\hat{\beta} - \hat{\beta}_{(i)})$ . Assim, a distância de Cook pode ser reescrita da seguinte forma:

$$D_i = \frac{(\hat{\beta} - \hat{\beta}_{(i)})^\top \mathbf{X}^\top \mathbf{X} (\hat{\beta} - \hat{\beta}_{(i)})}{p \times QME},$$

# Regressão Linear Múltipla

- Outra forma de calcular a distância de Cook seria um desenvolvimento das expressões anteriores:

$$D_i = \left( \frac{e_i}{\sqrt{(1 - h_{ii})QME}} \right)^2 \left( \frac{h_{ii}}{1 - h_{ii}} \right) \cdot \frac{1}{p} = \frac{r_i^2}{p} \cdot \frac{h_{ii}}{1 - h_{ii}},$$

sendo  $r_i$  o resíduo internamente estudentizado.

- Quanto a magnitude de  $D_i$ , podemos concluir que: observações com grande valor de  $D_i$  são aquelas nos quais, a exclusão irá resultar em grandes mudanças na análise.
- Regra básica: Se  $D_i \geq 0,80$ , a  $i$ -ésima observação será considerada influente.

# Regressão Linear Múltipla

- **DFBETAS:** Mede a alteração no valor  $\hat{\beta}_j$  ( $j = 0, 1, \dots, k$ ), quando a  $i$ -ésima observação é retirada das análises. A medida é dada pela diferença nas estimativas entre o coeficiente de regressão  $\hat{\beta}_j$  (baseado em todas as  $n$  observações), e o coeficiente de regressão  $\hat{\beta}_{j(i)}$  obtido quando o modelo é ajustado sem a observação  $i$ .
- A medida DFBETAS é definida como,

$$\text{DFBETAS}_{(i)} = \frac{\hat{\beta} - \hat{\beta}_{(i)}}{\sqrt{QME_{(i)} c_{jj}}},$$

onde  $c_{jj}$  é o  $j$ -ésimo elemento da diagonal da matriz  $(\mathbf{X}^\top \mathbf{X})^{-1}$ .

- É importante lembrar que,  $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$  e, portanto, a variância de  $\hat{\beta}_j$  é dada por:

$$\text{Var}(\hat{\beta}_j) = \sigma^2 c_{jj}.$$

# Regressão Linear Múltipla

- Regra básica:

A  $i$ -ésima observação é considerada ser influente se

$$|DFBETAS_{j(i)}| \geq \begin{cases} 1 & \text{para bancos pequenos ou médios} \\ \frac{2}{\sqrt{n}} & \text{para bancos de dados grandes.} \end{cases}$$

# Regressão Linear Múltipla

- **COVRATIO**: É uma estatística que mede a mudança no determinante na matriz de covariância das estimativas deletando a  $i$ -ésima observação.

$$\text{COVRATIO} = \frac{\det \left( QME_{(i)} \left( \mathbf{X}_{(i)}^{\top} \mathbf{X}_{(i)} \right)^{-1} \right)}{\det \left( QME \left( \mathbf{X}^{\top} \mathbf{X} \right)^{-1} \right)},$$

- onde  $\mathbf{X}_{(i)}$  é a matriz  $\mathbf{X}$  com a  $i$ -ésima linha deletada, e  $QME_{(i)}$ , é o  $QME$  obtido quando a  $i$ -ésima observação é omitida para ajustar o modelo de regressão.
- A estatística COVRATIO pode ser simplificada para:

$$\text{COVRATIO} = \left[ \left( \frac{n-p-1}{n-p} + \frac{t_i}{n-p} \right)^k (1 - h_{ii}) \right]^{-1}.$$



# Regressão Linear Múltipla

- Na expressão anterior,  $t_i$  é o resíduo externo estudentizado (ou resíduo deletado). Tal que,

$$t_i = \frac{e_i}{\hat{\sigma}_{(i)}\sqrt{1 - h_{ii}}} = \frac{e_i}{\sqrt{QME_{(i)}(1 - h_{ii})}}.$$

Tal que,  $t \sim t_{n-p}$ .

- Para o ponto de corte, Belsley, Kuh, and Welsch sugerem que observações com

$$|\text{COVRATIO} - 1| \geq \frac{3p}{n},$$

onde  $p = k + 1$  o número de coeficientes no modelo.

# Regressão Linear Múltipla

**Observação:** No pacote estatístico R, a  $i$ -ésima observação é considerada influente se:

- $|DFBetaS_{j(i)}| > 1$  para  $n$  (pequeno e moderado), e  $|DFBetaS_{j(i)}| > \frac{2}{\sqrt{n}}$ , caso contrário.
- $|DFFITS_{j(i)}| > 1$  para  $n$  (pequeno e moderado), e  $|DFFITS_{j(i)}| > 3\sqrt{\frac{p}{\sqrt{(n-p)}}}$ , caso contrário.
- COVRATIO, se:  $|1 - COVRATIO| > 3p/(n - p)$ .
- Distância de Cook, se  $D_{(i)} > F_{(0,5;p;n-p)}$ .
- Pontos de Alavancagem, se  $h_{ii} > 3p/n$ .

# Regressão Linear Múltipla

## Funções Estimáveis

- Conforme apresentado anteriormente, para o caso do MRLM,  $\mathbf{y} = \mathbf{X}\beta + \epsilon$ , a solução da equação  $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$  é única quando  $r(\mathbf{X}) = p$ .
- Portanto, quando  $r(\mathbf{X}) < p$ , existem infinitas soluções para  $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ , neste caso, devemos nos restringir apenas algumas funções de  $\beta$ .
- Tais funções/soluções para as quais devemos nos restringir (ou escolher), são chamadas de **estimáveis**.

# Regressão Linear Múltipla

**Definição 3:** Seja  $\mathbf{y}$  um vetor observado de  $\mathbf{y}$ , com distribuição conhecida. Uma função linear paramétrica  $\mathbf{c}^\top \boldsymbol{\beta}$  é dita ser estimável de  $\boldsymbol{\beta}$ , se existir um vetor  $n$ -dimensional  $\mathbf{t} = (t_1, t_2, \dots, t_n)^\top$ , tal que, a esperança da combinação linear  $\mathbf{t}^\top \mathbf{y} = \mathbf{c}^\top \boldsymbol{\beta}$  é,

$$\mathbb{E}(\mathbf{t}^\top \mathbf{y}) = \mathbf{t}^\top \mathbb{E}(\mathbf{y}) = \mathbf{c}^\top \boldsymbol{\beta}, \text{ com } \boldsymbol{\beta} \in \mathbb{R}^p, \text{ e}$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta}, \text{ e } \mathbf{c} = (c_1, \dots, c_p)^\top.$$

- De forma geral, uma função  $g(\boldsymbol{\beta})$  é dita ser estimável se existe uma função  $h(\mathbf{y})$  tal que,  $\mathbb{E}(h(\mathbf{y})) = g(\boldsymbol{\beta})$ , para qualquer  $\boldsymbol{\beta} \in \mathbb{R}^p$ , sendo então,  $h(\mathbf{y}) = \mathbf{t}^\top \mathbf{y}$  e  $g(\boldsymbol{\beta}) = \mathbf{c}^\top \boldsymbol{\beta}$ .

# Regressão Linear Múltipla

**Exemplo:** Como  $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \epsilon$  então, segue que:

$$\mathbb{E}(\mathbf{t}^\top \mathbf{y}) = \mathbf{t}^\top \mathbb{E}(\mathbf{y}) = \mathbf{t}^\top \mathbf{X}\boldsymbol{\beta} = \mathbf{c}^\top \boldsymbol{\beta} \implies \mathbf{t}^\top \mathbf{X} = \mathbf{c}^\top.$$

- Se  $r(\mathbf{X}) = p$  então,  $\mathbf{c}^\top \boldsymbol{\beta}$  é estimável, i.e.,  $\hat{\boldsymbol{\beta}}$  tem solução única.
- Quando  $r(\mathbf{X}) < p$ , algumas funções são estimáveis.
- Para garantir que uma função  $\mathbf{c}^\top \boldsymbol{\beta}$  é estimável, devemos verificar se  $\mathbf{t}^\top \mathbf{X} = \mathbf{c}^\top$ , para algum vetor  $\mathbf{t}$ .
- O valor esperado de qualquer observação é estimável.
- Qualquer combinação linear de funções estimáveis é estimável.
- Dada uma função estimável  $\mathbf{c}^\top \boldsymbol{\beta}$ , a quantidade  $\mathbf{c}^\top \tilde{\boldsymbol{\beta}}$  é invariante a escolha de  $\tilde{\boldsymbol{\beta}}$ .

# Regressão Linear Múltipla

## Teorema (Gauss-Markov)

Seja  $\mathbf{c}^\top \beta$  uma função estimável de  $\beta$ , e seja  $\tilde{\beta}$  uma solução qualquer para as equações normais.

(i) O teorema de Gauss-Markov afirma que,  $\mathbf{c}^\top \tilde{\beta}$  é o melhor estimador não-viesado de  $\mathbf{c}^\top \beta$  com variância,

$$\text{Var}(\mathbf{c}^\top \tilde{\beta}) = \mathbf{c}^\top \text{Var}(\tilde{\beta}) \mathbf{c} = \sigma^2 \mathbf{c}^\top \mathbf{G} \mathbf{c}$$

(ii) Se  $\tilde{\beta} = \hat{\beta}$ , então,

$$\text{Var}(\mathbf{c}^\top \hat{\beta}) = \mathbf{c}^\top \text{Var}(\hat{\beta}) \mathbf{c} = \sigma^2 \mathbf{c}^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{c}.$$