

# MÉTODO DOS MQ's GENERALIZADOS E PONDERADOS

Frederico Machado Almeida  
[frederico.almeida@unb.br](mailto:frederico.almeida@unb.br)

Departamento de Estatística  
Instituto de Exatas  
Universidade de Brasília

- Então o momento vimos que, a suposição principal do modelo de regressão linear,

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad (1)$$

é a de que o vetor dos erros  $\boldsymbol{\epsilon}$  é normalmente distribuídos com média  $\mathbf{0}$ , e variância  $\sigma^2 \mathbf{I}$ . Ou seja, que os erros são homoscedásticos.

- Entretanto, em muitas situações reais, a variância dos erros pode ser diferente para cada observação (problema de heterocedasticidade).

Isto é,  $\epsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma_i^2)$ .

- Até então vimos que, uma solução viável para estabilizar a variância dos erros seria transformar a variável de resposta  $y_i$ .
- A transformação da variável resposta tem as seguintes desvantagens:
  - (i) ela nem sempre é eficaz;
  - (ii) pode causar sérios problema de correlação serial;
  - (iii) pode resultar em uma relação não muito adequada para modelar o banco de dados.

- Quando a relação linear for adequada para modelar (1), porém, com variância não-constante, uma alternativa à transformação da variável resposta, seria usar alguns métodos de estimação considerados serem os mais robustos que os mínimos quadrados ordinários (MQO).
- Para contornar o problema da heterocedasticidade, iremos considerar como uma alternativa ao método dos MQO, os seguintes métodos de estimação:
  - Mínimos Quadrados Generalizados (MQG)
  - Mínimos Quadrados Ponderados (MQP): é considerado um caso particular dos MQG.

# Método dos Mínimos Quadrados Generalizados

- Considere o modelo de regressão linear múltipla

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \epsilon_i, \text{ com } \text{Var}(\epsilon_i) = \sigma_i^2,$$

como  $i = 1, \dots, n$ . Aqui,  $x_{ij}$  são elementos de  $\mathbf{X}$ . E,  $\beta_j$  com  $j = 0, \dots, p$  são os parâmetros do modelo.

- Como  $\text{Var}(\epsilon_i) = \sigma_i^2$ , então,  $\text{Var}(\epsilon) = \sigma_i^2 \mathbf{I}$  e portanto,

$$\text{Var}(\epsilon) = \begin{pmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n^2 \end{pmatrix} = \sigma^2 \mathbf{V}$$

# Método dos Mínimos Quadrados Generalizados

- Sendo  $\mathbf{V}$  uma matriz  $n \times n$  positiva definida. Assim, usando a notação matricial obtemos:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \text{ com } \text{Var}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{V}. \quad (2)$$

- Tal situação em que  $\text{Var}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{V}$  pode ser interpretada da seguinte forma:
  - Sendo  $\mathbf{V}$  uma matriz diagonal, mas com elementos diferentes, então, os  $y_i$ 's e os  $\epsilon_i$ 's são não correlacionados.
  - Se os elementos em  $\mathbf{V}$  ( $v_{ij} \neq 0$ , para todo  $i \neq j$ ), então, podemos afirmar que há correlação serial entre os erros.
  - Podemos então assumir que, para todo  $i = 1, \dots, n$  temos que  $\sigma_i^2 = \sigma^2 v_{ii}$ .
- Como a variância dos erros é viesada, a variância dos  $\hat{\boldsymbol{\beta}}$  também será viesada. Como consequência, os testes estatísticos são fortemente afetados

# Método dos Mínimos Quadrados Generalizados

- Sendo  $\mathbf{V}$  uma matriz não-singular e positiva definida, então, existe uma matriz  $\mathbf{K}_{n \times n}$  não-singular e simétrica, tal que

$$\mathbf{K}^\top \mathbf{K} = \mathbf{K} \mathbf{K}^\top = \mathbf{K} \mathbf{K} = \mathbf{V},$$

onde  $\mathbf{K} = \left( \sqrt{v_{ij}} \right)_{i,j=1,\dots,n}$ .

- É possível transformar o modelo em (2) da seguinte forma:

$$\underbrace{\mathbf{K}^{-1} \mathbf{y}}_{\mathbf{y}_g} = \underbrace{\mathbf{K}^{-1} \mathbf{X}}_{\mathbf{X}_g} \boldsymbol{\beta} + \underbrace{\mathbf{K}^{-1} \boldsymbol{\epsilon}}_{\boldsymbol{\epsilon}_g}, \text{ com } \text{Var}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{V}. \quad (3)$$

Aqui,  $\mathbf{y}_g = \mathbf{K}^{-1} \mathbf{y}$ ,  $\mathbf{X}_g = \mathbf{K}^{-1} \mathbf{X}$  e  $\boldsymbol{\epsilon}_g = \mathbf{K}^{-1} \boldsymbol{\epsilon}$  denotam as transformações do vetor de respostas, da matriz desenho e do vetor de erros aleatórios, respectivamente.

# Método dos Mínimos Quadrados Generalizados

- Com base nas variáveis transformadas, o modelo de regressão pode ser dada por:

$$\mathbf{y}_g = \mathbf{X}_g \boldsymbol{\beta} + \epsilon_g, \text{ com } \mathbb{E}(\epsilon_g) = \mathbf{0} \text{ e } \text{Var}(\epsilon_g) = \sigma^2 \mathbf{I}. \quad (4)$$

Prova:

$$(i) \mathbb{E}(\epsilon_g) = \mathbb{E}\left(\mathbf{K}^{-1}\epsilon\right) = \mathbf{K}^{-1}\mathbb{E}(\epsilon) = \mathbf{0}$$

$$\begin{aligned}(ii) \text{Var}(\epsilon_g) &= \mathbb{E}\left[(\epsilon_g - \mathbb{E}(\epsilon_g))(\epsilon_g - \mathbb{E}(\epsilon_g))^{\top}\right] = \mathbb{E}\left(\epsilon_g \epsilon_g^{\top}\right) \\&= \mathbb{E}\left[\mathbf{K}^{-1}\epsilon (\mathbf{K}^{-1}\epsilon)^{\top}\right] = \mathbb{E}\left[\mathbf{K}^{-1}\epsilon \epsilon^{\top} (\mathbf{K}^{\top})^{-1}\right] \\&= \mathbf{K}^{-1}\mathbb{E}\left[\epsilon \epsilon^{\top}\right] (\mathbf{K}^{\top})^{-1} \\&= \mathbf{K}^{-1}\sigma^2 \mathbf{V} (\mathbf{K}^{\top})^{-1} \\&= \sigma^2 \mathbf{I}.\end{aligned}$$

# Método dos Mínimos Quadrados Generalizados

- Assim, sob as suposições usuais segue que,  $\epsilon_g \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ .
- Os parâmetros do modelo em (4) podem ser estimados minimizando a soma do quadrado dos erros. Tal que,

$$\begin{aligned} SQE(\beta) &= (\mathbf{y}_g - \mathbf{X}_g \beta)^T (\mathbf{y}_g - \mathbf{X}_g \beta) \\ &= \mathbf{y}_g^T \mathbf{y}_g - 2\beta^T \mathbf{X}_g^T \mathbf{y}_g + \beta^T \mathbf{X}_g^T \mathbf{X}_g \beta. \end{aligned}$$

- O estimador dos MQG  $\hat{\beta}_g$  de  $\beta$  é dado por:

$$\begin{aligned} \hat{\beta}_g &= (\mathbf{X}_g^T \mathbf{X}_g)^{-1} \mathbf{X}_g^T \mathbf{y}_g \\ &= (\mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{K}^{-1})^T \mathbf{K}^{-1} \mathbf{y} \\ &= (\mathbf{X}^T \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{V}^{-1} \mathbf{y}. \end{aligned}$$

# Método dos Mínimos Quadrados Generalizados

- Pode-se mostrar facilmente que,  $\mathbb{E}(\hat{\beta}_g) = \beta$  e  $\text{Var}(\hat{\beta}_g) = \sigma^2 (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1}$ . Sendo  $\hat{\beta}_g$  um estimador não viesado com variância uniformemente menor (ENVUM).
- Sob as suposições usuais nos modelos de regressão linear, segue que,  $\hat{\beta}_g \sim \mathcal{N}\left(\beta, \sigma^2 (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1}\right)$ .
- Inferências sobre  $\hat{\beta}_g$  (testes de hipóteses e intervalos de confiança) segue a mesma ideia apresentada nas aulas anteriores.

# Método dos Mínimos Quadrados Generalizados

Exemplo Prático!!!

# Método dos Mínimos Quadrados Ponderados

- O método MQP pode ser visto como um caso particular do método dos MQG.
- Geralmente é recomendado quando os erros são não correlacionados,  $\text{Cov}(\epsilon_i, \epsilon_j) = 0, \forall i \neq j$ , mas com variâncias diferentes. Isto é,  $\text{Var}(\epsilon_i) = \sigma_i^2$ .
- Assim, vamos denotar por  $\mathbf{W}$  uma matriz de pesos, tal que,  $\mathbf{W} = \mathbf{V}^{-1}$ . Ou seja,

$$\text{Var}(\epsilon) = \sigma^2 \begin{pmatrix} \frac{1}{w_1} & 0 & \cdots & 0 \\ 0 & \frac{1}{w_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{w_n} \end{pmatrix} = \sigma^2 \mathbf{W}^{-1}.$$

Segue que,  $\text{Var}(\epsilon_i) = \frac{\sigma^2}{w_i}$ .

# Método dos Mínimos Quadrados Ponderados

- Sendo  $w_i$ , com  $i = 1, \dots, n$  quantidades conhecidas. De igual forma que  $\mathbf{V}$  é uma matriz diagonal,  $\mathbf{W} = \text{diag}(w_{ii})$ .
- Como  $\mathbf{K} = (\sqrt{v_{ij}})_{i,j=1,\dots,n}$ , segue imediatamente que  $\mathbf{K} = \mathbf{V}^{1/2}$ .  
Logo, obtemos o seguinte resultado:

$$\mathbf{W}^{1/2} = \mathbf{V}^{-1/2} = \mathbf{K}^{-1}.$$

- Com base no resultado do item anterior, é possível modificar a equação apresentada em (3) da seguinte forma:

$$\underbrace{\mathbf{W}^{1/2}\mathbf{y}}_{\mathbf{y}_w} = \underbrace{\mathbf{W}^{1/2}\mathbf{X}}_{\mathbf{X}_w}\beta + \underbrace{\mathbf{W}^{1/2}\epsilon}_{\epsilon_w}, \text{ com } \text{Var}(\epsilon) = \sigma^2 \mathbf{W}^{-1}. \quad (5)$$

# Método dos Mínimos Quadrados Ponderados

- Sendo,  $\mathbf{y}_w = \mathbf{W}^{1/2}\mathbf{y}$ ,  $\mathbf{X}_w = \mathbf{W}^{1/2}\mathbf{X}$  e  $\epsilon_w = \mathbf{W}^{1/2}\epsilon$  as variáveis ponderadas.
- Segue então que,
$$\mathbf{y}_w = \mathbf{X}_w\beta + \epsilon_w, \text{ com } \mathbb{E}(\epsilon_w) = \mathbf{0} \text{ e } \text{Var}(\epsilon_w) = \sigma^2\mathbf{I}. \quad (6)$$
- Aqui,  $\mathbf{y}_w = (w_1^{1/2}y_1, \dots, w_n^{1/2}y_n)^\top$ ;  $\mathbf{X}_w = (w_{ij}^{1/2}x_{ij})$  e,  $\epsilon_w = (w_1^{1/2}\epsilon_1, \dots, w_n^{1/2}\epsilon_n)^\top$ . Como consequência,
$$\epsilon_{wi} = w^{1/2}\epsilon_i = w^{1/2} \left( y_i - \beta_0 - \sum_{j=1}^n \beta_j x_{ij} \right).$$

# Método dos Mínimos Quadrados Ponderados

- A soma do quadrado dos erros, no contexto ponderado, é dada por:

$$\begin{aligned} \text{SQE}(\beta) &= \sum_{i=1}^n w_i \left( y_i - \beta_0 - \sum_{j=1}^n \beta_j x_{ij} \right)^2 \\ &= (\mathbf{y}_w - \mathbf{X}_w \beta)^\top (\mathbf{y}_w - \mathbf{X}_w \beta) \\ &= \mathbf{y}_w^\top \mathbf{y}_w - 2\beta^\top \mathbf{X}_w^\top \mathbf{y}_w + \beta^\top \mathbf{X}_w^\top \mathbf{X}_w \beta. \end{aligned}$$

- Derivando a  $\text{SQE}(\beta)$  em função de  $\beta$ , e igualando a zero obtemos o estimador dos MQP  $\hat{\beta}_w$  de  $\beta$ . Cuja expressão é dada por:

$$\begin{aligned} \hat{\beta}_w &= (\mathbf{X}_w^\top \mathbf{X}_w)^{-1} \mathbf{X}_w^\top \mathbf{y}_w \\ &= (\mathbf{X}^\top (\mathbf{W}^{1/2})^\top \mathbf{W}^{1/2} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{W}^{1/2})^\top \mathbf{W}^{1/2} \mathbf{y} \\ &= (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}. \end{aligned}$$

# Método dos Mínimos Quadrados Ponderados

- Pode-se mostrar facilmente que,  $\hat{\beta}_w$  é um estimador não-tendencioso para  $\beta$ , com variância  $\text{Var}(\hat{\beta}_w) = \sigma^2 (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1}$ .
- Como  $\mathbf{W}$  é uma matriz simétrica, segue imediatamente que,  $\mathbf{W}^{1/2}$  é igualmente simétrica, e portanto,  $\mathbf{W}^{1/2} (\mathbf{W}^{1/2})^\top = \mathbf{W}$ . Como consequência,  $\mathbf{W}^{-1/2} (\mathbf{W}^{-1/2})^\top = \mathbf{W}^{-1}$ .

# Método dos Mínimos Quadrados Ponderados

## Como escolher os pesos, $w_i$ ?

- A literatura dispõem de vários métodos de como os pesos,  $w_i$ , devem ser obtidos. De forma geral, a escolha dos pesos depende dos seguintes fatores:
  - i Se  $\text{Var}(Y_i) = X_i\sigma^2$  (com  $X_i > 0$ ) então,  $w_i \propto 1/X_i$ , e
  - ii Se  $\text{Var}(Y_i) = X_i^2\sigma^2$  (para todo  $X_i$ ) então,  $w_i \propto 1/X_i^2$
- Outras formas de obter os pesos estão resumidas abaixo:

# Método dos Mínimos Quadrados Ponderados

Resposta	$\bar{y}_i$
Tamanho	$n_i$
Variância amostral	$S_i^2$

Escolha de  $w_i$ :

i)  $w_i \propto n_i$  se  $\text{Var}(\bar{Y}_i) = \sigma^2/n_i$

ii)  $w_i \propto \frac{n_i}{S_i^2}$  se  $\text{Var}(\bar{Y}_i) = \sigma^2/n_i$

iii)  $w_i \propto \frac{1}{S_i^2}$  se  $\text{Var}(\bar{Y}_i) = \sigma^2/m.$

Sendo  $m$  o número de grupos em que os dados são divididos.

## ANÁLISE DE COVARIÂNCIA (ANCOVA)

# Análise de Covariância

- Os modelos da análise de covariância (ANCOVA) são, na verdade, uma mistura de modelos de regressão com modelos de análise de variância.
- A situação em que esses modelos são utilizados é, em essência, aquela em que as observações da variância dependente,  $Y$  são obtidas sob  $k$  condições diferentes, de forma que, para cada uma dessas condições, temos um grupo de observações.
- Tais grupos de observações de  $Y$  são representadas no modelo de regressão, por variáveis fictícias (variáveis *dummies*).
- Por exemplo, o modelo de regressão pode ser dado por:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \beta_{p+1} z_1 + \cdots + \beta_{p+k-1} z_{k-1} + \epsilon, \quad (7)$$

com  $z_j = 1$ , se a observação pertence ao grupo  $j$ , e 0 caso contrário.

# Análise de Covariância

- Como o objetivo principal do modelo de covariância é comparar a média  $\mu_y$  nos diferentes grupos, o modelo em (7) pode ser resumido em,

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \epsilon, \text{ se } z_j = 0 \quad \forall j$$

$$y = (\beta_0 + \beta_{p+1} + \cdots + \beta_{p+k-1}) + \beta_1 x_1 + \cdots + \beta_p x_p + \epsilon, \text{ se } z_j = 1 \quad \forall j$$

- Porém, vários outros submodelos intermediários podem ser listados.
- Além de listar os possíveis submodelos, o pesquisador pode estar interessado em incluir um efeito multiplicativo no modelo de regressão linear (*efeito de interação*).

# Análise de Covariância (Interação de Variáveis)

- Existem diferentes formas de incluir variáveis qualitativas no modelo. No entanto, a forma que tem frequentemente usada consiste em criar variáveis dummies.
- Em determinadas situações, variáveis quantitativas podem ser codificadas em níveis, podendo originar uma ou mais variáveis qualitativas.
- Por *interação* entende-se como sendo a situação onde o efeito combinado de duas ou mais variáveis independentes na média da variável resposta pode variar em função de acordo com os níveis das variáveis independentes.

# Análise de Covariância

**Exemplo 1:** Suponha que um médico está conduzindo um experimento no qual um grupo de pacientes foram subdivididos aleatoriamente em dois subgrupos: o grupo que recebeu o medicamento, e o que não recebeu. O objetivo do estudo é estudar o nível de redução do colesterol no organismo,  $y$ . Suponha que tenhamos também as variáveis, peso ( $x_1$ ), idade ( $x_2$ ). A variável tratamento foi categorizado tal que,

$$x_3 = \begin{cases} tto\ A, & \text{se recebeu o tratamento A} \\ tto\ B, & \text{se recebeu o tratamento B.} \end{cases}$$

Assim, o modelo de regressão pode ser formulado da seguinte forma:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \epsilon_i. \quad (8)$$

# Análise de Covariância

- Vamos definir a variável  $x_{3i}$  tal que,

$$x_3 = \begin{cases} 1, & \text{tto A} \\ 0, & \text{tto B.} \end{cases}$$

- Para cada nível da variável  $x_{3i}$ , os seguintes submodelos podem ser definidos:

$$y_{Ai} = (\beta_0 + \beta_3) + \beta_1 x_{1i} + \beta_2 x_{2i} + \epsilon_i, \quad \text{tto A}$$

$$y_{Bi} = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \epsilon_i, \quad \text{tto B.}$$

- Ou seja, a ideia da ANCOVA consiste na possibilidade de incluir não só variáveis quantitativas no modelo, mas também, de variáveis qualitativas. Como por exemplo, sexo, escolaridade, classe social, etc.

# Análise de Covariância (Interação de Variáveis)

## Definition (Interação de Variáveis)

A interação de variáveis se refere a condição em que o efeito de certas variáveis preditoras no modelo não é aditivo, mas sim, multiplicativo.

- Incluindo termo(s) de interação no modelo apresentado em (8) obtemos,

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_{13} x_{1i} x_{3i} + \beta_{23} x_{2i} x_{3i} + \epsilon_i. \quad (9)$$

- Neste caso obtemos os seguintes submodelos,

$$y_{Ai} = (\beta_0 + \beta_3) + (\beta_1 + \beta_{13}) x_{1i} + (\beta_2 + \beta_{23}) x_{2i} + \epsilon_i, \text{ tto A}$$

$$y_{Bi} = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \epsilon_i, \text{ tto B.}$$

# Análise de Covariância (Interação de Variáveis)

Observe que a interpretação dos coeficientes de regressão é tal que,

- $(\beta_1 + \beta_{13})$ : representa a variação (aumento ou redução) na média de  $y$  em pacientes que receberam o tto A, para cada variação unitária do peso ( $x_1$ ), mantendo constante a idade ( $x_2$ ).
- $(\beta_2 + \beta_{23})$ : representa a variação na média de  $y$  em pacientes que receberam o tto A, para cada variação unitária da idade ( $x_2$ ), mantendo constante a variável peso ( $x_1$ ).
- Note que nesse caso o intercepto  $\beta_0 + \beta_3$  não tem uma interpretação prática, já que, tanto  $x_1$ , como  $x_2$ , não podem assumir o valor 0.
- Para pacientes que receberam o tratamento do tipo B, a interpretação segue a mesma forma de um modelo usual.

## Análise de Covariância (Interação de Variáveis)

**Exemplo 2:** Considere o seguinte exemplo hipotético no qual o diretor de uma empresa pretende avaliar o impacto de certas variáveis na modelagem do escore de satisfação dos mesmos (assumindo valores de 0 a 100), e podendo assumir valores decimais. As variáveis de interesse são,  $x_1$  : sexo (0-M e 1-F);  $x_2$  : idade (em anos);  $x_3$  : nível de escolaridade (1-Superior, 0-caso contrário);  $x_4$  : salário (em reais), e  $x_5$  : experiência profissional (1-Com experiência, e 0-sem experiência).

- O modelo de interesse é dado por:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \epsilon_i. \quad (10)$$

- Note que por alguma eventualidade, o diretor da empresa pode estar interessado em avaliar, não só o efeito aditivo das covariáveis de regressão, mas também, o efeito aditivo (baseado no conhecimento à priori).

# Análise de Covariância (Interação de Variáveis)

- $x_1x_4$  : interação entre as variáveis sexo e salário.
- $x_2x_5$  : interação entre as variáveis idade e experiência profissional.
- $x_4x_3$  : interação entre as variáveis salário e escolaridade.
- $x_1x_3x_4$  : interação entre as variáveis sexo, escolaridade e salário, etc.

Ou seja, podemos escrever o novo modelo da seguinte forma:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_{14} x_{1i}x_{4i} + \beta_{25} x_{2i}x_{5i} + \beta_{34} x_{3i}x_{4i} + \beta_{134} x_{1i}x_{3i}x_{4i} + \epsilon_i. \quad (11)$$

## Análise de Covariância (Interação de Variáveis)

Com base no modelo apresentado em 12, vários submodelos podem ser obtidos, alguns dos quais incluem:

$$y_{Fi} = (\beta_0 + \beta_1) + \beta_2 x_{2i} + \beta_3 x_{3i} + (\beta_4 + \beta_{14}) x_{4i} + \beta_5 x_{5i} + \beta_{25} x_{2i} x_{5i} + (\beta_{34} + \beta_{134}) x_{3i} x_{4i} + \epsilon_i.$$

$$y_{Mi} = \beta_0 + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_{25} x_{2i} x_{5i} + \beta_{34} x_{3i} x_{4i} + \epsilon_i.$$

...

$$y_{FxSup} = (\beta_0 + \beta_1 + \beta_3) + \beta_2 x_{2i} + (\beta_4 + \beta_{14} + \beta_{34} + \beta_{134}) x_{4i} + \beta_5 x_{5i} + \beta_{25} x_{2i} x_{5i} + \epsilon_i.$$

$(\beta_4 + \beta_{14} + \beta_{34} + \beta_{134})$ : representa a mudança na média da variável resposta, nos funcionários do sexo feminino, com escolaridade superior, para cada variação unitária do salário dos funcionários, mantendo constante os demais fatores do modelo.