

Disciplina: Modelos Lineares Generalizados

Curso: Mestrado em Estatística

Código: PPGEST2217

Semestre: 2025.2

Professor: Frederico Machado Almeida

Observações:

- Questões para entregar: 2, 4, 5(d,e), 7 e 8.
- Demais questões são apenas para estudar.
- Prazo de entrega: **17/09/2025**

Q01. Responda as questões abaixo:

- (a) Seja A e B duas matrizes, cujo o produto é permutável. Mostre que $A^2 - B^2 = (A - B)C$, para alguma matriz C .
- (b) Se A e B são matrizes diagonais de dimensão $n \times n$, mostre que $AB = BA$.
- (c) Seja \mathbf{X} uma matriz $n \times k$, particionada como $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2)$, no qual \mathbf{X}_1 é $n \times k_1$ e \mathbf{X}_2 é $n \times k_2$.

(i) Mostre que

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} \mathbf{X}_1^\top \mathbf{X}_1 & \mathbf{X}_1^\top \mathbf{X}_2 \\ \mathbf{X}_2^\top \mathbf{X}_1 & \mathbf{X}_2^\top \mathbf{X}_2 \end{pmatrix}.$$

Qual é a dimensão de cada submatriz de $\mathbf{X}^\top \mathbf{X}$?

- (ii) Seja \mathbf{b} um vetor $k \times 1$ particionado como $\mathbf{b} = (\mathbf{b}_1, \mathbf{b}_2)^\top$, em que \mathbf{b}_1 é $k_1 \times 1$ e \mathbf{b}_2 é $k_2 \times 1$. Mostre que

$$(\mathbf{X}^\top \mathbf{X}) \mathbf{b} = \begin{pmatrix} \mathbf{X}_1^\top \mathbf{X}_1 \mathbf{b}_1 + \mathbf{X}_1^\top \mathbf{X}_2 \mathbf{b}_2 \\ \mathbf{X}_2^\top \mathbf{X}_1 \mathbf{b}_1 + \mathbf{X}_2^\top \mathbf{X}_2 \mathbf{b}_2 \end{pmatrix}.$$

Q02. Mostre que $(1/n) \mathbf{J}$ é uma matriz idempotente, $\mathbf{I} - (1/n) \mathbf{J}$ é igualmente idempotente, e $[\mathbf{I} - (1/n) \mathbf{J}] (1/n) \mathbf{J} = \mathbf{0}$. Sendo $\mathbf{J} = (a_{ij})$, com $a_{ij} = 1$ para todo $i, j = \{1, 2, \dots, n\}$.

Resposta: para responder essa questão, vamos usar o resultado da Definição 8 (Slides 10 da aula **GLM1-Álgebra Matricial**), tal que, $\mathbf{J}_{n \times n} \mathbf{J}_{n \times n} = n \mathbf{J}_{n \times n}$. Assim, (i) para mostrar que $(1/n) \mathbf{J}$ é uma matriz idempotente, segue que, $[(1/n) \mathbf{J}]^2 = n^{-2} \mathbf{J}^2 = n^{-2} n \mathbf{J} = n^{-1} \mathbf{J}$. (ii) Para mostrar que $\mathbf{I} - (1/n) \mathbf{J}$ é igualmente idempotente, segue que, $(\mathbf{I} - (1/n) \mathbf{J})^2 = [\mathbf{I} - (1/n) \mathbf{J}] [\mathbf{I} - (1/n) \mathbf{J}] = \mathbf{I}^2 - 2n^{-1} \mathbf{J} + n^{-2} \mathbf{J}^2 = \mathbf{I} - n^{-1} \mathbf{J}$, esse resultado segue da idempotência de \mathbf{I} e de $n^{-1} \mathbf{J}$ mostrado em (i). Por fim, (iii) vamos provar que $[\mathbf{I} - (1/n) \mathbf{J}] (1/n) \mathbf{J} = \mathbf{0}$. Para tal, $[\mathbf{I} - (1/n) \mathbf{J}] (1/n) \mathbf{J} = n^{-1} \mathbf{J} - n^{-2} \mathbf{J}^2 = n^{-1} \mathbf{J} - n^{-1} \mathbf{J} = \mathbf{0}$.

Q03. Considere o modelo de regressão linear simples $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$. Assuma $e_i = y_i - \hat{y}_i$ uma realização de ϵ_i , e $c_i = \frac{1}{n} - k_i \bar{x}$, com $k_i = (x_i - \bar{x}) / S_{xx}$. Mostre que:

- (a) $\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i$.
- (b) $\sum_{i=1}^n x_i e_i = 0$.
- (c) $\sum_{i=1}^n \hat{y}_i e_i = 0$.
- (d) $\sum_{i=1}^n c_i = 1$.
- (e) $\sum_{i=1}^n x_i c_i = 0$.

Q04. Assuma que a equação de regressão adequada para descrever as variações da resposta y_i é dada por: $y_i = \beta x_i + \epsilon_i$ (reta de regressão passando pela origem). Com $\epsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$. Sob a condição de que x_1, x_2, \dots, x_n são quantidades fixas e medidas sem erro, pede-se para:

- (a) Mostrar que o estimador dos mínimos quadrados de β é dado por, $\hat{\beta} = \sum_{i=1}^n k_i y_i$, com $k_i = \frac{x_i}{\sum_{i=1}^n x_i^2}$.

Resposta: observe que, para o modelo de regressão linear apresentado no enunciado, a soma dos quadrados dos erros é dada por: $SQE(\beta) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (y_i - \beta x_i)^2$. Desta forma, o estimador dos mínimos quadrados será obtido resolvendo a seguinte equação, $\frac{d}{d\beta} SQE(\beta) = -2 \sum_{i=1}^n (y_i - \beta x_i) x_i = 0$. Ou seja, a equação normal é dada

$$\text{por: } \sum_{i=1}^n (y_i - \hat{\beta} x_i) x_i = 0 \iff \hat{\beta} = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} = \sum_{i=1}^n k_i y_i, \text{ com } k_i = \frac{x_i}{\sum_{i=1}^n x_i^2}.$$

- (b) Mostre que $\hat{\beta}$ é um estimador não-viesado para β .

Resposta: do item (a) e do enunciado, segue que, $\mathbb{E}(Y_i | x_i) = \beta x_i$. Logo, $\mathbb{E}(\hat{\beta}) = \mathbb{E}\left[\sum_{i=1}^n k_i Y_i\right] = \sum_{i=1}^n k_i \mathbb{E}(Y_i) = \beta \sum_{i=1}^n k_i x_i = \beta \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n x_i^2} = \beta$. Portanto, concluímos que $\hat{\beta}$ é um estimador não-viesado para β .

- (c) Encontre a variância do estimador obtido em (a), e sua respectiva distribuição amostral.

Resposta: segue da definição do modelo de regressão linear simples que, $Var(Y_i) = Var(\beta x_i + \epsilon_i) = Var(\epsilon_i) = \sigma^2$. Assim,

$$Var(\hat{\beta}) = Var\left[\sum_{i=1}^n k_i Y_i\right] = \sum_{i=1}^n k_i^2 Var(Y_i) = \sigma^2 \frac{\sum_{i=1}^n x_i^2}{\left[\sum_{i=1}^n x_i^2\right]^2} = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}.$$

Correção: a distribuição amostral que o enunciado faz referência é com respeito ao estimador obtido em (a). Ou seja, supondo que os erros são normais, segue igualmente que, $\hat{\beta} \sim \mathcal{N}\left(\beta, \frac{\sigma^2}{\sum_{i=1}^n x_i^2}\right)$. No caso da distribuição amostral do estimador de σ^2 ,

segue que, $\frac{(n-1)SQRes}{\sigma^2} \sim \chi_{n-1}^2$, com $SQRes = \sum_{i=1}^n (y_i - \hat{\beta}x_i)^2$, que denota soma dos quadrados dos resíduos.

Q05. Considere o modelo de regressão linear simples $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, com $\mathbb{E}(\epsilon_i) = 0$, $\text{Var}(\epsilon_i) = \sigma^2$, e assuma que ϵ_i é não correlacionado. Pede-se para mostrar que:

- (a) $\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\bar{x}\sigma^2/S_{xx}$.
- (b) $\text{Cov}(\hat{\beta}_1(x_i - \bar{x}), y_j) = \frac{\sigma^2(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}$.
- (c) $\text{Cov}(y_i, \hat{y}_i) = \sigma^2 h_{ii}$
- (d) $\text{Var}(e_i) = (1 - h_{ii})\sigma^2$
- (e) $\text{Cov}(e_i, e_j) = -\sigma^2 h_{ij}$, para todo $i \neq j$.

Os itens (d) e (e) indicam que, apesar da suposição de homoscedasticidade e independência dos ϵ_i 's, os resíduos e_i são correlacionados, e sua variância depende dos valores de alavancagem.

Resp: (d) para responder esse item, vamos escrever o resíduo da seguinte forma: $e_i = y_i - \hat{y}_i = y_i - \sum_{j=1}^n h_{ij}y_j$. Desta forma, segue imediatamente que:

FORMA I:

$$\begin{aligned}
 \text{Var}(e_i) &= \text{Var}\left(Y_i - \sum_{j=1}^n h_{ij}Y_j\right) = \text{Var}(Y_i) + \text{Var}\left(\sum_{j=1}^n h_{ij}Y_j\right) - 2\text{Cov}\left(Y_i, \sum_{j=1}^n h_{ij}Y_j\right) \\
 &= \sigma^2 + \sum_{j=1}^n h_{ij}^2 \text{Var}(Y_j) - 2\text{Cov}\left(Y_i, \sum_{j=1}^n h_{ij}Y_j\right) \\
 &= \sigma^2 + \sigma^2 \sum_{j=1}^n h_{ij}^2 - \underbrace{2\text{Cov}(Y_i, h_{ii}Y_i)}_{\text{para algum } i=j} \\
 &= \sigma^2 + \sigma^2 h_{ii} - 2h_{ii}\sigma^2 \\
 &= \sigma^2(1 - h_{ii}).
 \end{aligned}$$

FORMA II: vamos reescrever o i -ésimo resíduo como $e_i = y_i - \hat{y}_i = y_i - \sum_{j=1}^n h_{ij}y_j = y_i(1 - h_{ii}) - \sum_{i \neq j} h_{ij}y_j$. Assim, segue imediatamente que,

$$\begin{aligned}
 Var(e_i) &= Var\left(Y_i(1 - h_{ii}) - \sum_{i \neq j} h_{ij}Y_j\right) \\
 &= Var(Y_i(1 - h_{ii})) + Var\left(\sum_{i \neq j} h_{ij}Y_j\right) - 2Cov\left(Y_i(1 - h_{ii}), \sum_{i \neq j} h_{ij}Y_j\right) \\
 &= (1 - h_{ii})^2 Var(Y_i) + \sum_{i \neq j} h_{ij}^2 Var(Y_j) - 2Cov\left(Y_i(1 - h_{ii}), \underbrace{\sum_{i \neq j} h_{ij}Y_j}_{=0, \text{ porque } i \neq j \text{ (parte vermelha)}}\right) \\
 &= (1 - 2h_{ii} + h_{ii}^2)\sigma^2 + \sum_{i \neq j} h_{ij}^2\sigma^2 = \sigma^2(1 - 2h_{ii}) + \sigma^2 \left(\underbrace{h_{ii}^2 + \sum_{i \neq j} h_{ij}^2}_{= \sum_{j=1}^n h_{ij}^2} \right) \\
 &= \sigma^2 - 2\sigma^2 h_{ii} + h_{ii}\sigma^2 = \sigma^2(1 - h_{ii}).
 \end{aligned}$$

FORMA III: considere a notação usual do i -ésimo resíduo. isto é, $e_i = y_i - \hat{y}_i$. Desta forma, segue que,

$$\begin{aligned}
 Var(e_i) &= Var(Y_i - \hat{Y}_i) = Var(Y_i) + Var(\hat{Y}_i) - 2Cov(Y_i, \hat{Y}_i) \\
 &= \sigma^2 + Var(\hat{\beta}_0 + \hat{\beta}_1 x_i) - 2Cov(Y_i, \hat{\beta}_0 + \hat{\beta}_1 x_i) \\
 &= \underbrace{\sigma^2}_{(i)} + \underbrace{Var(\hat{\beta}_0)}_{(ii)} + \underbrace{Var(\hat{\beta}_1 x_i)}_{(iii)} + \underbrace{2Cov(\hat{\beta}_0, \hat{\beta}_1 x_i)}_{(iii)} - \underbrace{2Cov(Y_i, \hat{\beta}_0)}_{(iv)} - \underbrace{2Cov(Y_i, \hat{\beta}_1 x_i)}_{(v)}.
 \end{aligned}$$

Observe que, (i) e (ii) sai imediatamente. Calculando as covariâncias em (iii)-(v), e substituindo na expressão anterior obtemos: $Var(e_i) = \sigma^2(1 - h_{ii})$.

Resposta: (e) segue da definição do resíduo que, $e_i = y_i - \hat{y}_i = y_i - \sum_{j=1}^n h_{ij}y_j$, e $e_j = y_j - \hat{y}_j = y_j - \sum_{j=1}^n h_{ij}y_j$, com a suposição de que $h_{ij} = h_{ji}$. Desta forma,

FORMA I:

$$\begin{aligned}
Cov(e_i, e_j) &= Cov\left(Y_i - \sum_{j=1}^n h_{ij}Y_j, Y_j - \sum_{j=1}^n h_{ij}Y_j\right) \\
&= Cov(Y_i, Y_j) - Cov\left(Y_i, \sum_{j=1}^n h_{ij}Y_j\right) - Cov\left(\sum_{j=1}^n h_{ij}Y_j, Y_j\right) + Cov\left(\sum_{j=1}^n h_{ij}Y_j, \sum_{j=1}^n h_{ij}Y_j\right) \\
&= \underbrace{Cov(Y_i, Y_j)}_{=0} - \underbrace{Cov(Y_i, h_{ii}Y_i)}_{\text{para algum } i=j} - \underbrace{Cov(h_{ij}Y_j, Y_j)}_{\text{para algum } j \text{ fixo}} + Var\left(\sum_{j=1}^n h_{ij}Y_j\right) \\
&= 0 - h_{ii}Cov(Y_i, Y_i) - h_{ij}Cov(Y_j, Y_j) + \sum_{j=1}^n h_{ij}^2 Var(Y_j) \\
&= -h_{ii}Var(Y_i) - h_{ij}Var(Y_j) + \sigma^2 \sum_{j=1}^n h_{ij}^2 = -h_{ii}\sigma^2 - h_{ij}\sigma^2 + \sigma^2 \underbrace{\sum_{j=1}^n h_{ij}^2}_{=h_{ii}} \\
&= -h_{ii}\sigma^2 - h_{ij}\sigma^2 + \sigma^2 h_{ii} \\
&= -h_{ij}\sigma^2.
\end{aligned}$$

FORMA II: segue da definição usual do resíduo que, $e_i = y_i - \hat{y}_i$ para o i -ésimo resíduo, e $e_j = y_j - \hat{y}_j$ para o j -ésimo resíduo. Segue então que,

$$\begin{aligned}
Cov(e_i, e_j) &= Cov(Y_i - \hat{Y}_i, Y_j - \hat{Y}_j) \\
&= Cov(Y_i, Y_j) - Cov(Y_i, \hat{Y}_j) - Cov(\hat{Y}_i, Y_j) + Cov(\hat{Y}_i, \hat{Y}_j) \\
&= 0 - Cov(Y_i, \hat{\beta}_0 + \hat{\beta}_1 x_j) - Cov(\hat{\beta}_0 + \hat{\beta}_1 x_i, Y_j) + Cov(\hat{\beta}_0 + \hat{\beta}_1 x_i, \hat{\beta}_0 + \hat{\beta}_1 x_j) \\
&= \underbrace{-Cov(Y_i, \hat{\beta}_0)}_{(i)} - \underbrace{-Cov(Y_i, \hat{\beta}_1 x_j)}_{(ii)} - \underbrace{-Cov(\hat{\beta}_0, Y_j)}_{(iii)} - \underbrace{-Cov(\hat{\beta}_1 x_i, Y_j)}_{(iv)} + Var(\hat{\beta}_0) \\
&\quad + \underbrace{Cov(\hat{\beta}_0, \hat{\beta}_1 x_j)}_{(v)} + \underbrace{Cov(\hat{\beta}_1 x_i, \hat{\beta}_0)}_{(vi)} + \underbrace{Cov(\hat{\beta}_1 x_i, \hat{\beta}_1 x_j)}_{(vii)}
\end{aligned}$$

Obs.: algumas das covariâncias apresentadas nos itens (i) a (vii) são obtidas facilmente, outras podem ser obtidas trocando os termos i e j . Por fim, juntando os resultados de (i) a (vii) obtemos: $Cov(e_i, e_j) = -h_{ij}\sigma^2$.

Q06. Sob as condições do modelo de regressão linear simples apresentado na **Q04**,

- Obtenha os estimadores de máxima verossimilhança para β_0 , β_1 e σ^2 .
- Verifique se os estimadores encontrados no em (a) são centrados nos verdadeiros valores.
- Do item (b), encontre a quantidade de viés presente no(s) estimador(es) que julgar ser(em) não-centrado(s). O que acontece com o viés quando o tamanho de amostra aumenta?

Q07. Considere o modelo de regressão linear simples $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, com $\epsilon_i \sim N(0, \sigma^2)$, seja SQT, SQReg e SQE as somas dos quadrados dos totais, da regressão e dos erros, respectivamente. Mostre que:

- (a) $\mathbb{E}(\text{SQReg}) = \sigma^2 + \beta_1^2 S_{xx}$.
 (b) $\mathbb{E}(\text{SQE}) = (n-2)\sigma^2$.
 (c) $\mathbb{E}(\text{SQT}) = \sigma^2(n-1) + \beta_1^2 S_{xx}$.

Resposta: (a) para mostrar as suposições abaixo, vamos fazer algumas simplificações para as somas dos quadrados. Como é de conhecimento, $\text{SQT} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2$, e

$$\begin{aligned} \text{SQReg} &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^n (\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{y})^2 \\ &= \sum_{i=1}^n (\bar{y} - \hat{\beta}_1 \bar{x} + \hat{\beta}_1 x_i - \bar{y})^2 \\ &= \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \hat{\beta}_1^2 S_{xx}. \end{aligned}$$

Assim, segue imediatamente que,

$$\begin{aligned} \mathbb{E}(\text{SQReg}) &= \mathbb{E}(\hat{\beta}_1^2 S_{xx}) = S_{xx} \mathbb{E}(\hat{\beta}_1^2) = S_{xx} [\text{Var}(\hat{\beta}_1) + \mathbb{E}^2(\hat{\beta}_1)] \\ &= S_{xx} \left[\frac{\sigma^2}{S_{xx}} + \beta_1^2 \right] = \sigma^2 + \beta_1^2 S_{xx}. \end{aligned}$$

(b) uma forma fácil de provar a suposição do item (b), segue do fato de que $\text{SQE} = \text{SQT} - \text{SQReg}$. Consequentemente, $\mathbb{E}(\text{SQE}) = \mathbb{E}(\text{SQT}) - \mathbb{E}(\text{SQReg})$. Desta forma, seja $\mu_{y_i/x_i} = \beta_0 + \beta_1 x_i$ o valor esperado de y_i , dado x_i . Assim, $\mu_{\bar{y}|\bar{x}} = \beta_0 + \beta_1 \bar{x}$. Consequentemente, segue imediatamente que,

$$\begin{aligned} \mathbb{E}(\text{SQT}) &= \sum_{i=1}^n \mathbb{E}(Y_i^2) - n\mathbb{E}(\bar{Y}^2) = \sum_{i=1}^n [\text{Var}(Y_i) + \mathbb{E}^2(Y_i)] - n[\text{Var}(\bar{Y}) + \mathbb{E}^2(\bar{Y})] \\ &= \sum_{i=1}^n [\sigma^2 + \mu_{y_i/x_i}^2] - n \left[\frac{\sigma^2}{n} + \mu_{\bar{y}|\bar{x}}^2 \right] = \sigma^2(n-1) + \sum_{i=1}^n (\beta_0 + \beta_1 x_i)^2 - n(\beta_0 + \beta_1 \bar{x})^2 \\ &= \sigma^2(n-1) + n\beta_0^2 + n\beta_0\beta_1\bar{x} + \sum_{i=1}^n \beta_1^2 x_i^2 - n\beta_0^2 - n\beta_0\beta_1\bar{x} - n\beta_1^2 \bar{x}^2 \\ &= \sigma^2(n-1) + \beta_1^2 \left[\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right] \\ &= \sigma^2(n-1) + \beta_1^2 S_{xx}. \end{aligned}$$

Por fim, temos que: $\mathbb{E}(\text{SQE}) = \sigma^2(n-1) + \beta_1^2 S_{xx} - [\sigma^2 + \beta_1^2 S_{xx}] = \sigma^2(n-2)$.

Q08. Suponha que estamos interessados em ajustar o modelo de regressão linear simples $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ porém decidiu-se reescalonar a variável regressora tomando-a como o desvio com relação a sua média, isto é, $x_i^* = x_i - \bar{x}$, com $i = 1, \dots, n$.

- (a) Prove que o modelo que relaciona y_i e a nova variável regressora x_i^* é $y_i = \beta_0^* + \beta_1 x_i^* + \epsilon_i$, onde $\beta_0^* = \beta_0 + \beta_1 \bar{x}$.

Resposta: segue da definição do modelo de regressão linear simples que, $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$. Como $x_i^* = x_i - \bar{x}$, segue que, $x_i = x_i^* + \bar{x}$. Logo, substituindo x_i na expressão anterior obtemos:

$$\begin{aligned} y_i &= \beta_0 + \beta_1 x_i + \epsilon_i = \beta_0 + \beta_1 (x_i^* + \bar{x}) + \epsilon_i \\ &= (\beta_0 + \beta_1 \bar{x}) + \beta_1 x_i^* + \epsilon_i = \beta_0^* + \beta_1 x_i^* + \epsilon_i \end{aligned}$$

- (b) Prove que o estimador dos mínimos quadrados para β_0^* é igual a \bar{y} , e que o estimador para β_1 permanece igual ao do modelo original.

Resposta: segue do modelo em (a) $y_i = \beta_0^* + \beta_1 x_i^* + \epsilon_i$ que, $\epsilon_i = y_i - \beta_0^* + \beta_1 x_i^*$. A soma do quadrado dos erros, SQE para o modelo anterior é, $SQE = \sum_{i=1}^n (y_i - \beta_0^* + \beta_1 x_i^*)^2$.

Derivando em relação a β_0^* e β_1 obtemos:

$$\begin{cases} \frac{dSQE}{d\beta_0^*} = -2 \sum_{i=1}^n (y_i - \beta_0^* - \beta_1 x_i^*) = 0 \\ \frac{dSQE}{d\beta_1} = -2 \sum_{i=1}^n x_i^* (y_i - \beta_0^* - \beta_1 x_i^*) = 0 \end{cases} \implies \begin{cases} \sum_{i=1}^n y_i - n\beta_0^* - \beta_1 \sum_{i=1}^n x_i^* = 0 \\ \sum_{i=1}^n x_i^* y_i - \beta_0^* \sum_{i=1}^n (x_i - \bar{x}) - \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \end{cases}$$

segue da suposição de que $\sum_{i=1}^n (x_i - \bar{x}) = 0$. Assim, chegamos a conclusão que $\hat{\beta}_0^* = \bar{y}$.

Por fim, substituindo o resultado de (1) em (2) obtemos:

$$\begin{cases} \sum_{i=1}^n y_i - n\beta_0^* - \beta_1 \sum_{i=1}^n (x_i - \bar{x}) = 0 & (1) \\ \sum_{i=1}^n (x_i - \bar{x}) y_i - \beta_0^* \sum_{i=1}^n (x_i - \bar{x}) - \beta_1 \sum_{i=1}^n (x_i - \bar{x})^2 = 0 & (2) \end{cases} \implies \begin{cases} \hat{\beta}_0^* = \bar{y} \\ \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \end{cases}$$

- (c) Prove que ambos os modelos fornecem os mesmos valores preditos para y .

Resposta: com base os estimadores dos mínimos quadrados obtidos anteriormente, associado as suposições anteriores temos que, $\hat{\beta}_0^* = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$. Consequentemente,

$$\hat{y}_i^* = \hat{\beta}_0^* + \hat{\beta}_1 x_i^* = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} + \hat{\beta}_1 (x_i - \bar{x}) = \hat{\beta}_0 + \hat{\beta}_1 \bar{x} + \hat{\beta}_1 x_i - \hat{\beta}_1 \bar{x} = \hat{\beta}_0 + \hat{\beta}_1 x_i \equiv \hat{y}_i.$$

Q09. Faça uma simulação, gerando 50 valores para o modelo de regressão linear simples (MRLS), $y_i = -1 + 0.3x_i + \epsilon_i$, com $\epsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, 1)$. Assuma que $X \sim U[-1, 1]$. Ajuste o MRLS, e obtenha o diagrama de dispersão com a reta ajustada.