

# Lista 1

## Técnicas Computacionais em Estatística

Tailine J. S. Nonato

April 8, 2025

### Lista 1 - Geração de NPA's (Números Pseudo-Aleatórios)

```
# preparação do ambiente  
set.seed(345)
```

#### Exercício 1

A distribuição Laplace padrão tem densidade  $f(x) = \frac{1}{2}e^{-|x|}$ ,  $x \in \mathbb{R}$ . Use o método da transformada inversa para gerar uma amostra aleatória de tamanho 1000 dessa distribuição. Plote um histograma.

#### Resolução

A função de distribuição acumulada (cdf) da distribuição Laplace padrão é dada por:

$$F(x) = \begin{cases} \frac{1}{2}e^x, & x < 0 \\ 1 - \frac{1}{2}e^{-x}, & x \geq 0 \end{cases}$$

Para  $u \leq \frac{1}{2}$ :

$$u = \frac{1}{2}e^x \Rightarrow x = \log(2u)$$

Para  $u > \frac{1}{2}$ :

$$u = 1 - \frac{1}{2}e^{-x} \Rightarrow x = -\log(2(1-u))$$


Logo, a inversa da cdf é dada por:

$$F^{-1}(u) = \begin{cases} \log(2u), & u \leq \frac{1}{2} \\ -\log(2(1-u)), & u > \frac{1}{2} \end{cases}$$

Assim,

```
n <- 1000
u <- runif(n)
x <- ifelse(u <= 0.5, log(2*u), -log(2*(1 - u)))

t <- seq(-10, 10, 0.01)
hist(x, probability = TRUE, main = "", breaks = 30)
lines(t, 0.5 * exp(-abs(t)), col = "red")
```



## Exercício 2

Dada a densidade  $f(x \mid \theta)$  e a densidade a priori  $\pi(\theta)$ , se observamos  $x = x_1, \dots, x_n$ , a distribuição a posteriori de  $\theta$  é dada por:

$$\pi(\theta | x) = \pi(\theta | x_1, \dots, x_n) \propto \prod_i f(x_i | \theta) \pi(\theta),$$

onde  $\prod_i f(x_i | \theta) = L(\theta | x_1, \dots, x_n)$  é a função de verossimilhança. Para estimar uma média normal, uma priori robusta é a Cauchy. Para  $X_i \sim N(\theta, 1)$ ,  $\theta \sim \text{Ca}(0, 1)$ , a distribuição a posteriori é:

$$\pi(\theta | x) \propto \frac{1}{\pi} \frac{1}{1 + \theta^2} \frac{1}{(2\pi)^{n/2}} \prod_{i=1}^n e^{-(x_i - \theta)^2 / 2}.$$

Seja  $\theta_0 = 3$ ,  $n = 10$ , e gere  $X_1, \dots, X_n \sim N(\theta_0, 1)$ . Use o algoritmo da Aceitação-Rejeição com uma candidata  $\text{Ca}(0, 1)$  para gerar uma amostra da distribuição a posteriori. Avalie quão bem o valor  $\theta_0$  é recuperado. Estenda o código de maneira que  $n = 10, 25, 50, 100$ . Assuma que  $M = L(\hat{\theta} | x_1, \dots, x_n)$ , ou seja,  $M$  é a função de verossimilhança avaliada no estimador de máxima verossimilhança.

### Resolução

Sendo  $f$ : densidade alvo (a qual se deseja simular) e  $g$ : densidade candidata ou instrumental, tem-se

$f$ :  $\pi(\theta | x)$ ,  $\theta \sim \text{Ca}(0, 1)$ , com  $M = L(\hat{\theta} | x_1, \dots, x_n)$

$g$ :  $\text{Ca}(0, 1)$ ,  $\theta \sim \text{Ca}(0, 1)$

### Exercício 3

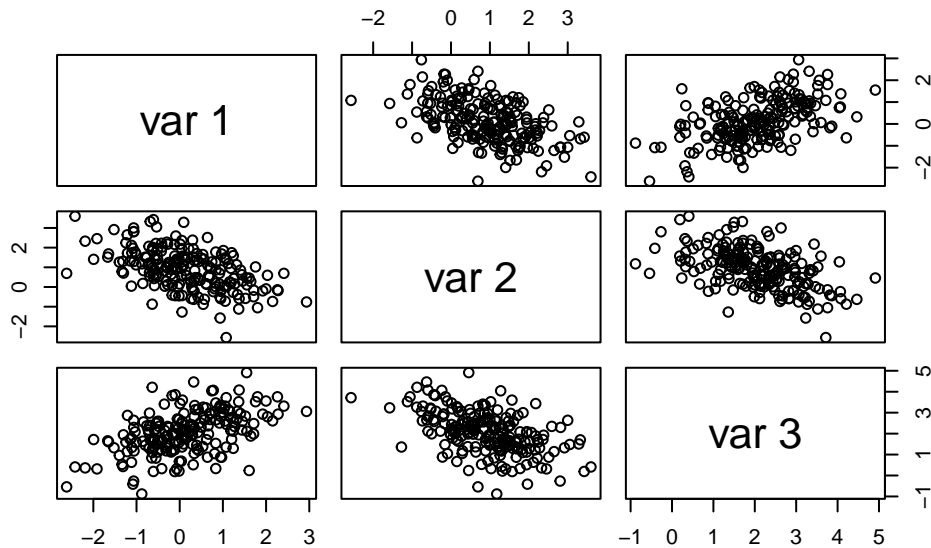
Gere 200 observações aleatórias de uma distribuição normal multivariada de dimensão 3 com vetor de médias  $\mu = (0, 1, 2)^\top$  e matriz de covariância:

$$\Sigma = \begin{bmatrix} 1.0 & -0.5 & 0.5 \\ -0.5 & 1.0 & -0.5 \\ 0.5 & -0.5 & 1.0 \end{bmatrix}.$$

Use o método de decomposição de Cholesky.

## Resolução

```
rmvn.Choleski <- function(n, mu, Sigma) {  
  d <- length(mu)  
  Q <- chol(Sigma)  
  Z <- matrix(rnorm(n*d), nrow=n, ncol=d)  
  X <- Z %*% Q + matrix(mu, n, d, byrow=TRUE)  
  X}  
  
Sigma <- matrix(c(1.0, -0.5, 0.5,  
                 -0.5, 1.0, -0.5,  
                 0.5, -0.5, 1.0), nrow = 3, byrow = TRUE)  
  
mu <- c(0, 1, 2)  
n <- 200  
X <- rmvn.Choleski(n, mu, Sigma)  
pairs(X)
```



## Exercício 4

Considere o artigo “Bivariate Birnbaum–Saunders distribution and associated inference” (Kundu et al., 2010), disponível em PDF, onde os autores apresentam uma formulação

para a distribuição bivariada de Birnbaum–Saunders (BVBS). A geração de dados desta distribuição é descrita na equação (8) do artigo. Utilize a parametrização apresentada no artigo para simular 1.000 observações de um vetor aleatório bivariado  $(T_1, T_2)$  com distribuição BVBS( $\alpha_1 = 0.5, \alpha_2 = 0.8, \beta_1 = 1.0, \beta_2 = 2.0, \rho = 0.7$ ). Apresente um gráfico de dispersão dos dados gerados.

### Resolução

```
alpha1 <- 0.5
alpha2 <- 0.8
beta1 <- 1
beta2 <- 2
rho <- 0.7
```

- Step 1: Generate independent  $U_1$  and  $U_2$  from  $N(0, 1)$ .

```
U1 <- rnorm(1000, 0, 1)
U2 <- rnorm(1000, 0, 1)
```

- Step 2: Compute

$$Z_1 = \frac{\sqrt{1+\rho} + \sqrt{1-\rho}}{2} * U_1 + \frac{\sqrt{1+\rho} - \sqrt{1-\rho}}{2} * U_2$$

$$Z_2 = \frac{\sqrt{1+\rho} - \sqrt{1-\rho}}{2} * U_1 + \frac{\sqrt{1+\rho} + \sqrt{1-\rho}}{2} * U_2$$

```
Z1 <- (sqrt(1 + rho) + sqrt(1 - rho)) / 2 * U1 +
      (sqrt(1 + rho) - sqrt(1 - rho)) / 2 * U2
Z2 <- (sqrt(1 + rho) - sqrt(1 - rho)) / 2 * U1 +
      (sqrt(1 + rho) + sqrt(1 - rho)) / 2 * U2
```

- Step 3: Obtain

$$T_i = \beta_i \left[ \frac{1}{2} \alpha_i Z_i + \sqrt{\left( \frac{1}{2} \alpha_i Z_i \right)^2 + 1} \right]^2, \quad i = 1, 2$$

```
T1 <- beta1 * (0.5 * alpha1 * Z1 + sqrt((0.5 * alpha1 * Z1)^2 + 1))^2  
T2 <- beta2 * (0.5 * alpha2 * Z2 + sqrt((0.5 * alpha2 * Z2)^2 + 1))^2
```

- Gráfico de dispersão dos dados gerados:

```
plot(T1, T2, xlab = "T1", ylab = "T2", main = "Gráfico de dispersão dos dados gerados")
```

